TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN ĐHQG HCM

BÁO CÁO ĐỒ ÁN



ĐỒ ÁN MÔN: Xử lý ngôn ngữ tự nhiên

GV: Ths. Nguyễn Trọng Chỉnh

Đề tài: Sentiment and topic classification in Vietnamese context

Nhóm AAA

23520276 – Trương Hoàng Đạt

23520520 – Lê Chí Hoàng

This page was left blank intentionally

TÓM TẮT

Nghiên cứu này tập trung giải quyết bài toán phân loại đa nhiệm trên dữ liệu văn bản tiếng Việt, cụ thể là đồng thời xác định cảm xúc và chủ đề của câu nói trong cùng một kiến trúc mô hình thống nhất. Thay vì tiếp cận theo hướng huấn luyện các mô hình đơn lẻ cho từng tác vụ, chúng tôi đề xuất kiến trúc chia sẻ tham số cứng dựa trên các mô hình ngôn ngữ tiền huấn luyện tiên tiến như PhoBERT, XLM-RoBERTa và ViSoBERT.

Bên cạnh đó, để giải quyết các thách thức về tài nguyên tính toán và dữ liệu mất cân bằng, nghiên cứu đã áp dụng và đánh giá hiệu quả của các kỹ thuật tối ưu hóa hiện đại bao gồm: Thích nghi hạng thấp (LoRA), Điều chuẩn trơn (SMART Regularization) và Học kết hợp tác vụ phụ (Masked Language Modeling). Kết quả thực nghiệm trên bộ dữ liệu NEU-ESC cho thấy phương pháp đề xuất không chỉ cải thiện độ chính xác tổng thể mà còn tăng cường khả năng tổng quát hóa và ổn định của mô hình so với các phương pháp tinh chỉnh truyền thống.

CHƯƠNG 1: GIỚI THIỆU

1.1. Đặt vấn đề

Sự bùng nổ của mạng xã hội và thương mại điện tử đã tạo ra nguồn dữ liệu văn bản khổng lồ chứa đựng ý kiến người dùng. Việc phân tích ý kiến này đòi hỏi hệ thống trí tuệ nhân tạo không chỉ nhận diện được sắc thái tình cảm (Tích cực, Tiêu cực, Trung tính) mà còn phải xác định được ngữ cảnh hoặc khía cạnh mà người dùng đang đề cập (như Giá cả, Dịch vụ, hay Chất lượng sản phẩm). Mối tương quan giữa cảm xúc và chủ đề là rất chặt chẽ, việc tách rời hai bài toán này thường dẫn đến mất mát thông tin ngữ cảnh quan trọng.

1.2. Thách thức

Việc xây dựng mô hình phân loại đa nhiệm cho tiếng Việt gặp phải các thách thức chính:

- **Đặc thù ngôn ngữ:** Tiếng Việt có cấu trúc ngữ pháp phức tạp, ranh giới từ không rõ ràng và sự đa dạng của từ lóng, viết tắt trên mạng xã hội.
- **Dữ liệu mất cân bằng:** Sự phân bố không đồng đều giữa các nhãn cảm xúc và chủ đề khiến mô hình dễ bị thiên lệch về phía các lớp đa số.
- **Tài nguyên tính toán:** Các mô hình ngôn ngữ lớn (LLM) đòi hỏi chi phí huấn luyện cao, khó triển khai trong điều kiện tài nguyên hạn chế.

1.3. Mục tiêu nghiên cứu

- Xây dựng kiến trúc Deep Learning thống nhất có khả năng trích xuất đặc trưng ngữ nghĩa và chia sẻ tri thức giữa hai tác vụ phân loại.
- Tối ưu hóa quá trình huấn luyện bằng các kỹ thuật tiên tiến nhằm giảm thiểu chi phí tính toán và hiện tượng quá khớp (overfitting).

- Đánh giá hiệu quả của các kiến trúc Encoder-only và Seq2Seq trên dữ liệu tiếng Việt.

CHƯƠNG 2: GIỚI THIỆU, PHÂN TÍCH DATASET

2.1 Phân tích bộ dữ liệu và thiết lập đánh giá

Bộ dữ liệu NEU-ESC bao gồm các bình luận tiếng Việt trong nhiều ngữ cảnh khác nhau, với phân bố nhãn không đồng đều giữa các lớp cảm xúc và chủ đề. Đặc điểm này phản ánh sát thực tế các bài toán phân tích ý kiến người dùng, nhưng đồng thời cũng đặt ra thách thức lớn cho quá trình huấn luyện và đánh giá mô hình.

Bộ dữ liệu NEU-ESC một bộ dữ liệu tiếng Việt được thu thập từ các forum, nhóm Facebook, và cộng đồng học thuật trực tuyến phản ánh ngôn ngữ thực tế của sinh viên — bao gồm tiếng lóng, dùng teencode, lỗi chính tả, và cách diễn đạt không chính thống từ các diễn đàn trực tuyến gồm 32966 mẫu: 23048 mẫu train, 3305 mẫu validation, 6613 mẫu test. Gồm có 4 nhãn cảm xúc, và 10 nhãn chủ đề với phân phối như bảng dưới

Bảng thông tin về các nhãn cảm xúc

Nhãn	Cảm xúc	Số lượng	Tỉ lệ	Độ dài trung bình câu
0	Neutral	22,773	69.08%	23.21
1	Positive	4,148	12.58%	24.29
2	Negative	5,250	15.77%	34.30
3	Toxic	845	2.56%	22.78

Bảng thông tin về các nhãn chủ đề

Nhãn	Chủ đề	Số lượng	Tỉ lệ	Độ dài trung bình câu
0	Spam	405	1.23%	22.71
1	News	902	2.74%	59.55
2	Academic	10,512	31.89%	29.62
3	Other	14,402	43.69%	11.40

4	**Service**	**2,358**	**7.15%**	**30.94**
5	**Jobs & Recruitment**	**808**	**2.45%**	**55.14**
6	**Personal Affairs**	**1,478**	**4.48%**	**33.17**
7	**Social Affairs**	**769**	**2.33%**	**67.11**
8	**Help & Share**	**670**	**2.03%**	**37.03**
9	**Club & Events**	**662**	**2.01%**	**68.82**

2.2 Phân Tích Các Yếu Tố Ảnh Hưởng Đến Gán Nhãn (Feature Importance)

A. Đối với Topic

- **Nhãn 2: Học tập & Hỏi đáp (Academic/Inquiry)**
  - **Từ khóa nhận diện:** Chứa các thực thể liên quan đến đào tạo và quy trình nhà trường.
  - **Feature Words:** đăng ký học ghép, giấy phép hành nghề, viện sản, ngành, đào thải, mô hình sư phạm, thầy cô, lớp.
  - **Văn phong:** Thường lịch sự, dùng kính ngữ (ạ, mong anh chị, xin chào), câu hỏi cấu trúc rõ ràng.
- **Nhãn 3: Other**
  - **Từ khóa nhận diện:** Ngôn ngữ sinh hoạt, slang (từ lóng), các chủ đề ngoài việc học chính thức.
  - **Feature Words:** trai trường, báo (báo đời), ngủ, admin, duyệt bài, tiền thưởng, ban cán sự.
  - **Văn phong:** Teencode (dồi, ý), câu ngắn, mang tính kể lể hoặc giải trí (vui tính quá, lười lắm).
- **Nhãn 4: Dịch vụ (Service)**
  - **Từ khóa nhận diện:** Các từ chỉ sự cố, mất mát, hoặc cảm giác khó chịu về dịch vụ/cơ sở vật chất.
  - **Feature Words:**
    - *Về tiền/dịch vụ:* mất 800, sửa linh tinh, làm đổ xe, không xong.
    - *Về cơ sở vật chất:* tầng nóng, chảy mỡ.
    - *Về thái độ/hành chính:* hằn giọng, rén ngang (sợ), hành chính.

B. Đối với Sentiment

- **Nhãn 2: Tiêu cực (Negative)**
  - Đây là nhãn dành cho các cảm xúc tiêu cực **mạnh** và rõ ràng.
  - **Tín hiệu ngôn ngữ:**
    - Động từ/Tính từ mạnh: ghét, khóc lóc, ăn vạ, hoang mang, sợ.
    - Từ chỉ hậu quả xấu: mất tiền, sửa linh tinh, làm sai.

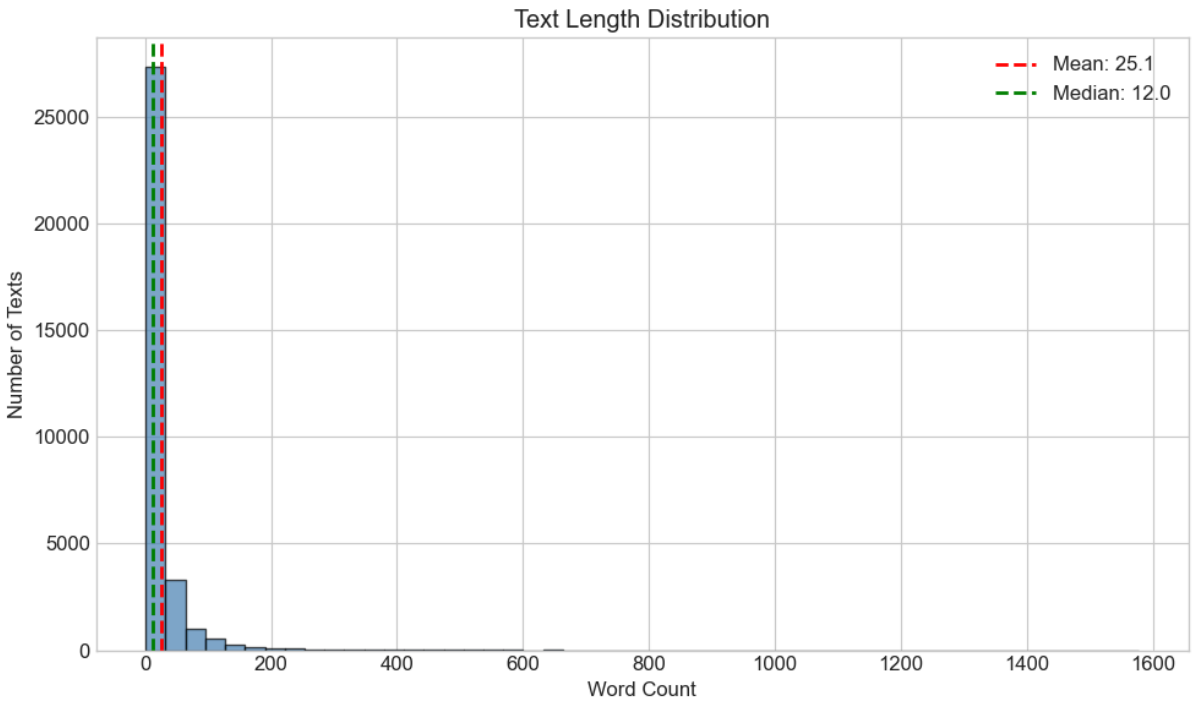
    - *Ví dụ trong file:* Dòng than vãn về sửa xe mất 800k, dòng drama "ghét cái kiểu làm sai".
- **Nhãn 1: Tích cực (Positive)**
    - **Tín hiệu ngôn ngữ:** Các tính từ chỉ niềm vui trực tiếp.
    - *Ví dụ trong file:* "thi đi xã **vui lắm**".
- **Nhãn 0: Trung tính/Hỗn hợp (Neutral/Mixed)**
    - **Lưu ý quan trọng:** Nhãn 0 trong dữ liệu này bao phủ rất rộng, bao gồm cả:
        - Hỏi đáp thông thường ("xin chào... review giúp em").
        - Khen ngợi nhẹ hoặc bông đùa ("hay quá", "vui tính quá").
        - Than vãn nhẹ nhàng/hài hước ("lười lắm dồi", "báo quá").
    - Điều này cho thấy nhãn 0 đóng vai trò là lớp "Mặc định" (Default class) cho những câu không quá tiêu cực (nhãn 2).

Nhận xét về Dữ liệu & Gợi ý (Data Insight)

- **Sự phân hóa của Nhãn 4 (Topic):** Nhãn 4 rất thú vị vì nó gom cả việc "sửa xe bên ngoài" và "thái độ hành chính trong trường". Điểm chung của chúng là **trải nghiệm tồi tệ (Bad Experience)**. Nếu huấn luyện mô hình, các từ khóa như "mất", "tệ", "sợ", "nóng" sẽ có trọng số cao cho nhãn này.
- **Biên giới giữa Nhãn 0 và 2 (Sentiment):** Có sự chồng lấn nhẹ. Ví dụ: "báo quá" (gây rắc rối) hay "rén ngang" (sợ) mang nghĩa tiêu cực nhưng lại được gán nhãn 0 (có thể do người gán nhãn coi đó là văn phong hài hước của Gen Z). Chỉ những tiêu cực nghiêm trọng (ghét, mất tiền thật) mới bị gán nhãn 2.
- **Dự báo phân loại:**
    - Nếu câu chứa thầy cô, môn học → Khả năng cao là **academic**.
    - Nếu câu chứa tiền, sửa, nóng, hành chính (kèm từ ngữ tiêu cực) → Khả năng cao là **service**
    - Các trường hợp còn lại (đời sống, tình cảm, slang) → **other**.

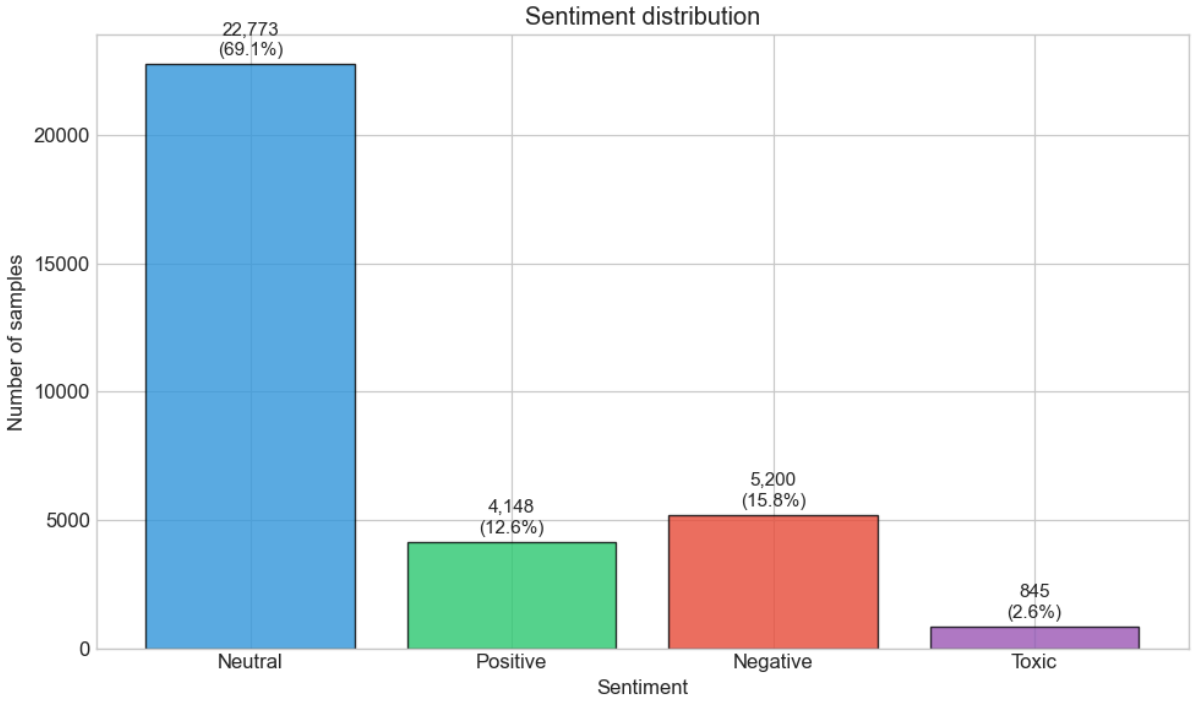
2.3 EDA:

Bảng phân bố độ dài câu của toàn bộ tập dữ liệu như sau



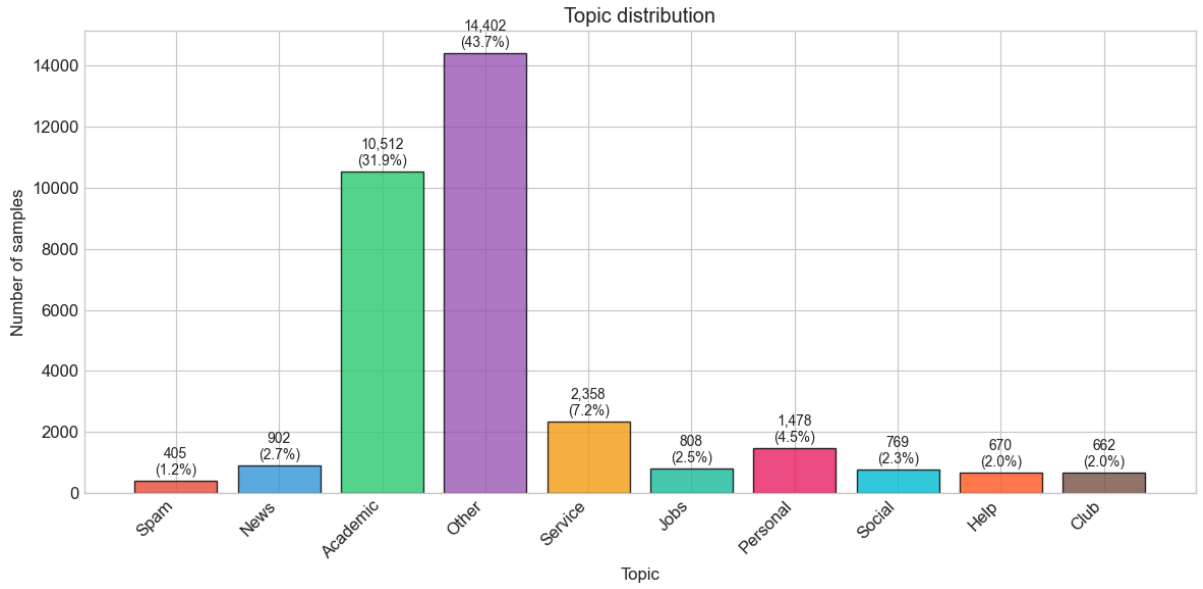
Các câu có độ dài ngắn nhất là 1 từ, dài nhất là 1578 từ, có 12759 từ khác nhau. Phần lớn các câu có độ dài từ 1 - 50 từ

Bảng phân bố các nhãn cảm xúc như sau:



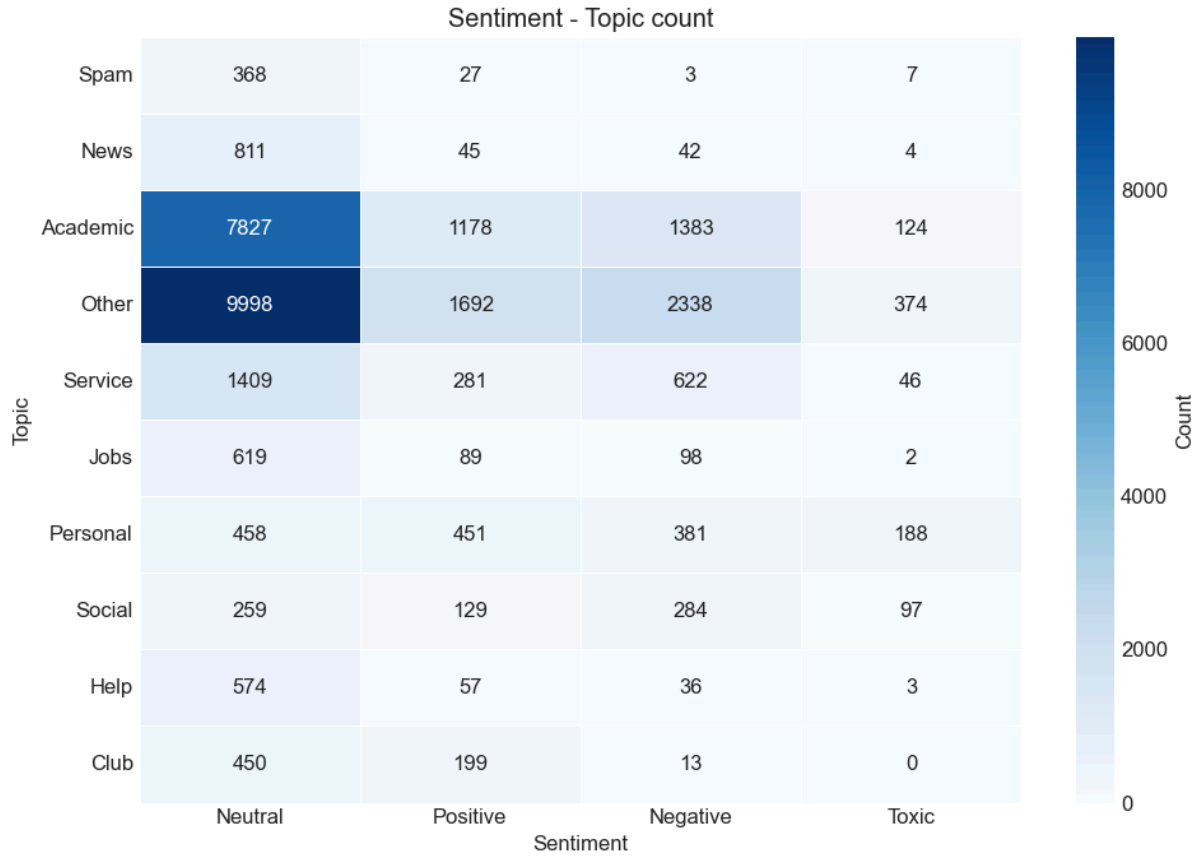
Có thể thấy dữ liệu có sự mất cân bằng lớn, với phần lớn các nhãn là Neutral, chiếm tới 69.1%, trong khi bình luận nhãn Toxic chỉ chiếm 2.6%, điều này có thể gây khó khăn khi nhận diện các câu thuộc nhãn này

Bảng phân bố nhãn topic như sau:



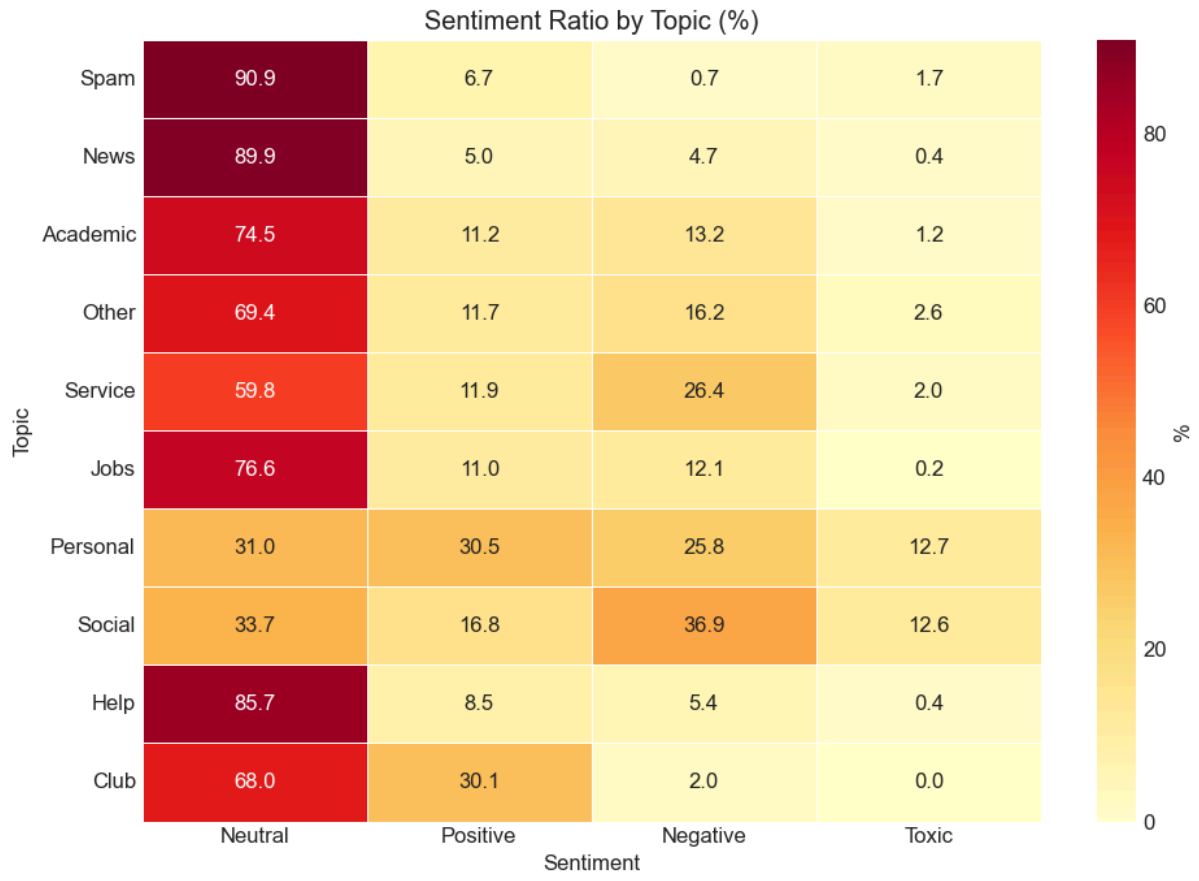
Tương tự như trên, dữ liệu cũng có sự mất cân bằng lớn với chủ yếu các nhãn topic là Other và Academic

Bảng phân bố dữ liệu theo cảm xúc và topic



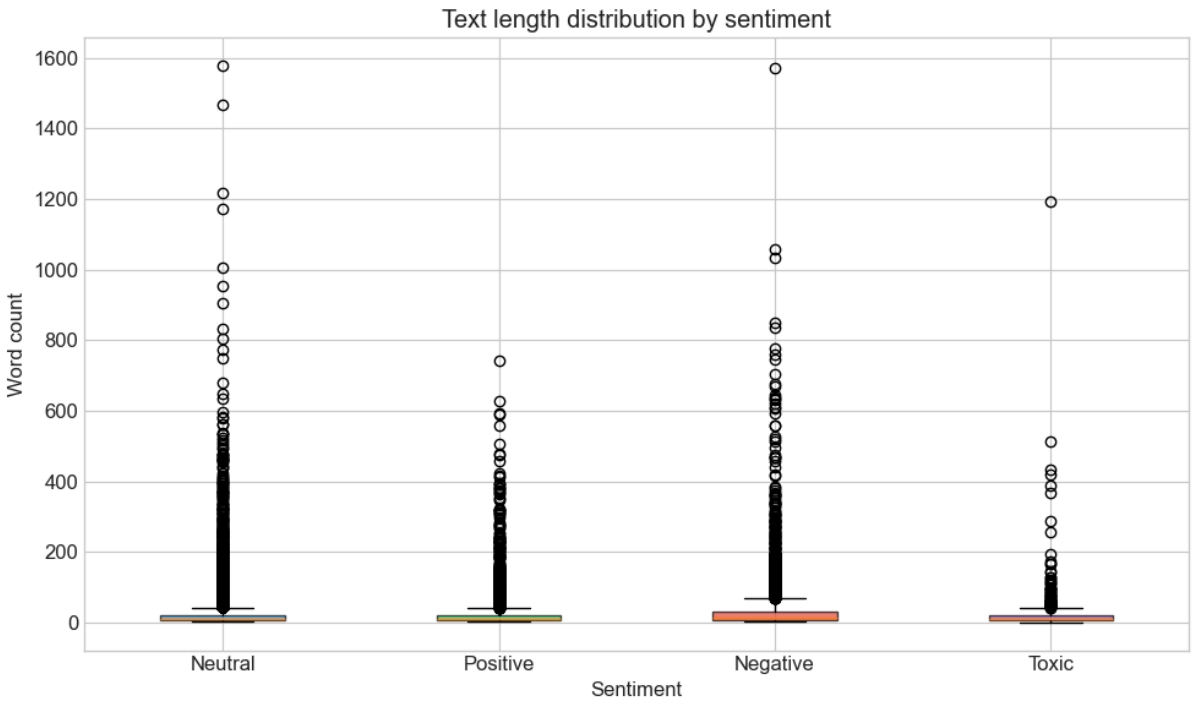
Các dữ liệu phần lớn tập trung ở nhãn Neutral - Academic và Neutral - Other

Bảng phân phối tỉ lệ phần trăm của các nhãn cảm xúc theo từng topic



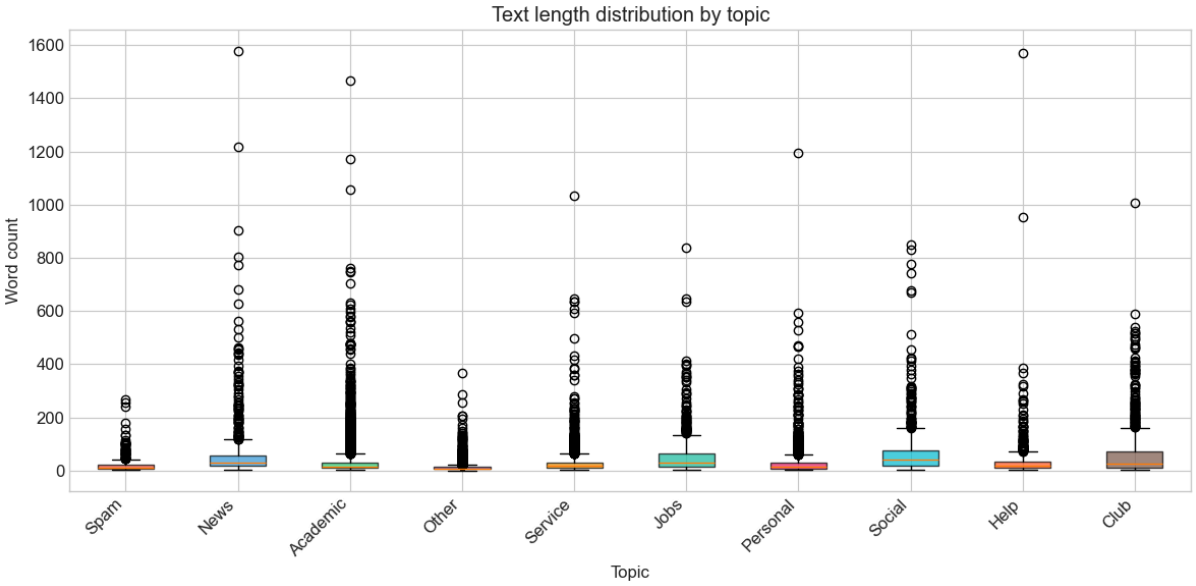
Ở tất cả các topic, nhãn cảm xúc Neutral chiếm rất nhiều, từ 31 - 90.9%

Bảng box plot độ dài câu theo nhãn cảm xúc



Các câu có nhãn toxic thường có độ dài nhỏ hơn so với các nhãn còn lại

Bảng box plot độ dài câu theo nhãn topic



CHƯƠNG 3: PHƯƠNG PHÁP THỰC HIỆN

3.1. Tổng quan phương pháp tiếp cận

Nhóm nghiên cứu giải quyết bài toán phân loại đa nhiệm (tận dụng hai tác vụ Sentiment và Topic) dựa trên **học chuyển giao** với các mô hình ngôn ngữ tiền huấn luyện (PLMs). Cụ thể, chúng tôi sử dụng các PLM đã được huấn luyện trên tập dữ liệu lớn (như PhoBERT, XLM-RoBERTa, v.v.) rồi **tinh chỉnh (fine-tune)** trên bộ dữ liệu chuyên biệt của đề tài. Ví dụ, PhoBERT – mô hình BERT cho tiếng Việt – được huấn luyện trên ~20GB văn bản tiếng Việt và đạt kết quả SOTA trên nhiều tác vụ xử lý ngôn ngữ. Phương pháp này cho phép tận dụng kiến thức tổng quát từ ngữ liệu lớn, đồng thời điều chỉnh cho phù hợp với miền nhiệm vụ cụ thể.

Chiến lược thực nghiệm được chia thành hai nhóm kiến trúc chính:

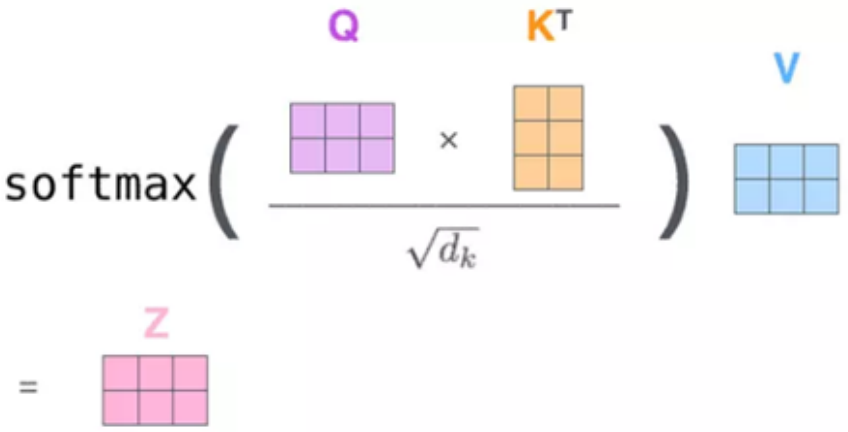
- **Encoder-only:** Sử dụng các mô hình Transformer chỉ có phần Encoder, chuyên trích xuất đặc trưng ngữ nghĩa từ văn bản. Đại diện bao gồm PhoBERT, XLM-RoBERTa và ViSoBERT.
- **Encoder-Decoder (Seq2Seq):** Sử dụng mô hình Transformer đầy đủ (encoder-decoder) để giải bài toán phân loại dưới dạng sinh văn bản. Trong nhóm này có các mô hình như ViT5 và BARTpho, tiếp cận bài toán dưới góc độ Text-to-Text.

3.2. Các kiến trúc mô hình đề xuất

Nhóm kiến trúc được đề xuất bao gồm hai loại như trên, nhằm so sánh hiệu quả giữa phương pháp trích xuất đặc trưng (encoder-only) và phương pháp sinh văn bản (seq2seq). Tất cả mô hình đều được tinh chỉnh từ trọng số tiền huấn luyện, với hai đầu ra phân loại riêng cho Sentiment và Topic.

3.2.1. Nhóm mô hình Encoder-only (PhoBERT, XLM-RoBERTa, ViSoBERT)

Các mô hình encoder-only dựa trên kiến trúc Transformer chỉ dùng phần **Encoder** để mã hóa câu đầu vào thành vectơ ngữ nghĩa. Bản chất của Transformer là sử dụng cơ chế **self-attention đa đầu**, cho phép mô hình tính trọng số giữa các cặp từ thông qua quan hệ truy vấn – khóa – giá trị (query, key, value). Cụ thể, tại mỗi vị trí, từ hiện tại sẽ là vector truy vấn (Q), so sánh với các vector khóa (K) của tất cả từ khác để tính trọng số chú ý và kết hợp tương ứng với giá trị (V).



souce: Attention Networks: A simple way to understand Self-Attention

Đầu ra của Encoder là vector đại diện cho toàn bộ câu (thường lấy tại token đặc biệt [CLS]). Để giải bài toán đa nhiệm, chung phần Encoder này sẽ được kết nối tới hai tầng phân loại riêng biệt: một tầng cho Sentiment và một tầng cho Topic. Cụ thể, vectơ đặc trưng chung được nối tiếp với một lớp fully-connected cho từng nhánh nhiệm vụ. Như vậy, kiến trúc Encoder-only vừa tận dụng được biểu diễn chung, vừa dự báo đồng thời hai loại nhãn.

Các mô hình cụ thể:

- **PhoBERT:** Mô hình BERT đơn ngữ đầu tiên cho tiếng Việt, sử dụng kiến trúc RoBERTa. PhoBERT được huấn luyện trên ~20GB văn bản tiếng Việt (Wikipedia) và thể hiện hiệu quả vượt trội trên nhiều tác vụ ngôn ngữ tự nhiên (POS, NER, …) của tiếng Việt. Trong bài toán phân loại, PhoBERT được dùng để trích xuất đặc trưng ngôn ngữ chung trước khi phân loại.
- **ViSoBERT:** Mô hình được thiết kế dành riêng cho văn bản mạng xã hội tiếng Việt. ViSoBERT theo kiến trúc XLM-R và được tiền huấn luyện trên một tập lớn dữ liệu bài đăng, bình luận mạng xã hội. Kết quả cho thấy ViSoBERT vượt trội so với các PLM trước đó ở các nhiệm vụ xã hội như nhận diện cảm xúc, phát hiện ngôn từ căm ghét, phân tích cảm xúc văn bản…. Mặc dù kích thước nhỏ hơn, ViSoBERT vẫn đạt hiệu năng SOTA với bộ tham số ít hơn đáng kể.
- **XLM-RoBERTa:** Mô hình đa ngôn ngữ được huấn luyện trên 100 ngôn ngữ (gồm cả tiếng Việt) với 2.5TB dữ liệu CommonCrawl sạch. XLM-R được ghi nhận cải thiện rõ rệt trên nhiều tác vụ so với các mô hình đa ngữ trước đó như mBERT. Chúng tôi sử dụng XLM-R để đánh giá khả năng tổng quát hóa của mô hình đa ngữ so với các mô hình đơn ngữ.

3.2.2. Nhóm mô hình Encoder-only và Chiến lược tinh chỉnh nâng cao

Ngoài kiến trúc cơ bản của Transformer Encoder, nhóm nghiên cứu áp dụng quy trình xử lý dữ liệu đặc thù và các kỹ thuật tối ưu hóa **(MLM, SMART)** để nâng cao hiệu suất phân loại đa nhiệm.

a. Chi tiết kiến trúc và Tiền xử lý dữ liệu (Data Preprocessing)

Dựa trên đặc thù của từng mô hình, quy trình tiền xử lý được thiết kế riêng biệt để phù hợp với cách thức huấn luyện ban đầu:

- **PhoBERT-base-v2:**
    - Kiến trúc: Sử dụng kiến trúc RoBERTa với 12 tầng transformer, kích thước ẩn (hidden size) 768, và 12 đầu chú ý (attention heads), tổng cộng khoảng 135 triệu tham số.
    - Tiền xử lý: PhoBERT yêu cầu tách từ (word segmentation) trước khi tokenize. Nhóm sử dụng thư viện VnCoreNLP để nối các từ ghép bằng dấu gạch dưới (ví dụ: "sinh viên" à "sinh_viên"). Sau đó, áp dụng BPE (Byte Pair Encoding) để chuyển văn bản thành token IDs, thêm các token đặc biệt <s> (đầu câu) và </s> (cuối câu), đồng thời cắt hoặc thêm padding để đạt độ dài chuẩn (max 256 tokens).
- **XLM-RoBERTa-base:**
    - Kiến trúc: Mô hình đa ngôn ngữ huấn luyện trên 2.5TB dữ liệu CommonCrawl, kích thước lớn hơn với khoảng 270 triệu tham số.
    - Tiền xử lý: Sử dụng mô hình ngôn ngữ Unigram để tokenize trực tiếp mà không cần bước tách từ như PhoBERT.
- **ViSoBERT:**
    - Kiến trúc: Dựa trên XLM-R nhưng được huấn luyện chuyên biệt trên dữ liệu mạng xã hội (Facebook, TikTok, YouTube), giúp xử lý tốt teencode và các ký tự nhiễu. Tương tự XLM-R, mô hình này không yêu cầu tách từ trong tiền xử lý.

b. Kiến trúc tinh chỉnh đa nhiệm (Multi-task Fine-tuning Architecture)

Để giải quyết đồng thời hai tác vụ Sentiment và Topic, kiến trúc mạng được thiết kế như sau:

- Shared Encoder: Văn bản đầu vào đi qua tầng Encoder (PhoBERT/XLM-R/ViSoBERT) để tạo ra vector biểu diễn ngữ nghĩa.
- Shared Layer & Classification Heads: Vector đặc trưng đi qua một lớp tuyến tính chung (Shared Linear Layer) và chuẩn hóa lớp (Layer Normalization). Sau đó, nó được rẽ nhánh vào hai đầu phân loại riêng biệt (Task 1: Sentiment, Task 2: Topic)[1].

Các kĩ thuật được sử dụng chung trong quá trình train như sau:

- Sử dụng Focal Loss để nhấn mạnh mô hình tập trung sửa lỗi ở các class thiểu số
- Sử dụng learning rate riêng cho backbone và classifier head, vì backbone đã được finetune trước với lượng lớn dữ liệu, trọng số đã tối ưu tốt nên dùng learning rate nhỏ để không cập nhật quá nhiều. Với classifier head, vì trọng số mới khởi tạo và cần thời gian hội tụ nên dùng learning rate lớn hơn
- Sử dụng Gradient clipping đã tránh gradient quá lớn, làm hỏng mô hình khi cập nhật
- Linear Schedule with Warmup, dùng learning rate tăng dần ở đoạn đầu để mô hình nhanh hội tụ, sau đó giảm dần để tránh cập nhật quá lớn
- Sử dụng Focal Loss để nhấn mạnh mô hình tập trung sửa lỗi ở các class thiểu số

c. Kỹ thuật tối ưu hóa quá trình Fine-tuning

Nhằm cải thiện khả năng tổng quát hóa và độ chính xác, ngoài việc tinh chỉnh thông thường, nhóm nghiên cứu tích hợp hai kỹ thuật nâng cao:

1. Masked Language Modeling (MLM) như một tác vụ phụ trợ

Thay vì chỉ có 2 đầu ra (Sentiment, Topic), mô hình được mở rộng thành kiến trúc 3-head bằng cách thêm một đầu MLM (Masked Language Model).

- Cơ chế: Trong quá trình fine-tune, 30% số token đầu vào được chọn ngẫu nhiên để che đi (trong đó 80% thay bằng <MASK>, 10% thay bằng từ ngẫu nhiên, 10% giữ nguyên).
- Hàm mất mát (Loss function): Loss của MLM thường lớn hơn loss của phân loại, do đó được chia tỉ lệ cho số lượng token bị che trung bình n. Tổng loss được tính theo công thức:

$$\mathcal{L}_{total} = \mathcal{L}_{sentiment} + \mathcal{L}_{topic} + \frac{\mathcal{L}_{MLM}}{n}$$

2. Kỹ thuật SMART (Smoothness-inducing Adversarial Regularization)

Đây là kỹ thuật giúp mô hình ổn định hơn với nhiễu và tránh overfitting (học vẹt) thông qua hai thành phần chính:

- **Smoothness-inducing Adversarial Regularization:** Chủ động thêm một lượng nhiễu nhỏ $\tilde{r}$ vào đầu vào để làm thay đổi kết quả dự đoán nhiều nhất, sau đó phạt mô hình nếu kết quả đầu ra thực sự thay đổi so với ban đầu. Hàm phạt dựa trên độ sai biệt Kullback-Leibler (KL Divergence):

$$\mathcal{L}_s = D_{KL}(P(y|x)||P(y|x+\tilde{r}))$$

- **Bregman Proximal Point Optimization:** Ngăn cản mô hình thay đổi trọng số quá nhanh trong quá trình cập nhật, giúp giữ lại các tri thức đã học từ giai đoạn tiền huấn luyện (pre-training):

$$\mathcal{L}_b = D_{KL}(P_{\theta^{(t-1)}}(y|x)||P_{\theta^{(t)}}(y|x))$$

Hàm loss tổng hợp khi áp dụng SMART:

$$\mathcal{L} = \mathcal{L}_{task} + \lambda \mathcal{L}_{SMART}$$

3.2.3. Tiếp cận mô hình Seq2Seq theo hướng Encoder-only (ViT5, BartPHO)

Mặc dù các mô hình như **ViT5** và **BartPHO** được thiết kế theo kiến trúc **Encoder–Decoder (Seq2Seq)**, trong phạm vi đề tài này, nhóm nghiên cứu **chỉ khai thác phần Encoder** của các mô hình nhằm đảm bảo tính công bằng khi so sánh với nhóm Encoder-only (PhoBERT, XLM-RoBERTa, VisoBERT), đồng thời tập trung đánh giá hiệu quả của các **chiến lược fine-tuning** (Full Fine-tuning và LoRA).

Cơ sở lựa chọn phương pháp

Có ba lý do chính cho việc chỉ sử dụng Encoder của các mô hình Seq2Seq:

1. **Tính nhất quán trong so sánh thực nghiệm**
   Việc sử dụng chung một cơ chế suy luận (classification head trên embedding câu) cho tất cả mô hình giúp đảm bảo rằng sự khác biệt về hiệu năng đến từ:
   - kiến trúc nền (PLM),
   - và chiến lược fine-tuning (Full vs. LoRA),
     thay vì do khác biệt về cơ chế sinh văn bản (generation).
2. **Tối ưu tài nguyên tính toán**
   Decoder trong các mô hình Seq2Seq chiếm tỷ lệ lớn về số tham số và chi phí huấn luyện. Việc loại bỏ Decoder giúp:
   - giảm đáng kể bộ nhớ GPU,
   - rút ngắn thời gian huấn luyện,
   - phù hợp hơn với mục tiêu đánh giá LoRA trong điều kiện tài nguyên hạn chế.
3. **Phù hợp với bài toán phân loại**
   Với bài toán phân loại đa nhiệm (Sentiment và Topic), đầu ra mong muốn là **nhãn rời rạc**, không yêu cầu sinh chuỗi tự hồi quy. Do đó, việc sử dụng biểu diễn ngữ nghĩa từ Encoder là đủ và hiệu quả.

Cách thức áp dụng Encoder của mô hình Seq2Seq

Quy trình áp dụng được thực hiện như sau:

- Văn bản đầu vào X được đưa qua **Encoder** của mô hình ViT5 hoặc BartPHO.
- Vector biểu diễn toàn câu được trích xuất từ:
  - token đầu tiên (ví dụ <s>), hoặc
  - trung bình (mean pooling) của các hidden states cuối.
- Vector này được chia sẻ cho hai **classification head độc lập**:
  - một head dự đoán nhãn **Sentiment**,
  - một head dự đoán nhãn **Topic**.

Toàn bộ Decoder bị **loại bỏ** trong quá trình huấn luyện và suy luận.

Vai trò của LoRA trong nhóm mô hình Seq2Seq-Encoder

Do ViT5 và BartPHO có số lượng tham số lớn hơn đáng kể so với các mô hình Encoder-only truyền thống, đây là nhóm mô hình **đặc biệt phù hợp để đánh giá hiệu quả của LoRA**.

Trong thiết lập LoRA:

- Các trọng số gốc của Encoder được **đóng băng hoàn toàn**.
- Chỉ các ma trận hạng thấp (Low-Rank matrices) được chèn vào các lớp attention (Query, Key, Value) và được cập nhật trong quá trình huấn luyện.
- Số tham số cần huấn luyện giảm mạnh, trong khi vẫn giữ được khả năng thích nghi với dữ liệu mới.

Mục tiêu chính của việc áp dụng LoRA trong đề tài là:

Tối thiểu hóa số lượng tham số trainable và chi phí huấn luyện, trong khi vẫn duy trì độ chính xác tiệm cận so với Full Fine-tuning.

Kết quả thực nghiệm (trình bày ở Chương 4) cho thấy với các mô hình lớn như ViT5 Encoder, LoRA giúp giảm đáng kể tài nguyên huấn luyện, và tuy có suy giảm nhẹ về F1-score so với Full Fine-tuning, mức suy giảm này là **chấp nhận được** trong bối cảnh đánh đổi giữa hiệu năng và chi phí tính toán.

Tóm tắt

Khác với cách tiếp cận text-to-text truyền thống của Seq2Seq, đề tài này:

- **chỉ sử dụng Encoder** của ViT5 và BartPHO,
- đưa bài toán về dạng **classification-based**, tương tự nhóm Encoder-only,
- từ đó tập trung đánh giá ảnh hưởng của **Full Fine-tuning so với LoRA** một cách công bằng và rõ ràng.

Cách tiếp cận này cho phép làm nổi bật vai trò của LoRA như một kỹ thuật **fine-tuning hiệu quả, tiết kiệm tham số**, đặc biệt phù hợp với các mô hình ngôn ngữ lớn cho tiếng Việt trong điều kiện tài nguyên hạn chế.

3.3. Kỹ thuật tinh chỉnh (Fine-tuning Strategy)

Để đạt hiệu suất tốt trên nhiệm vụ chuyên biệt và khai thác tối ưu nguồn lực tính toán, chúng tôi triển khai song song hai chiến lược huấn luyện:

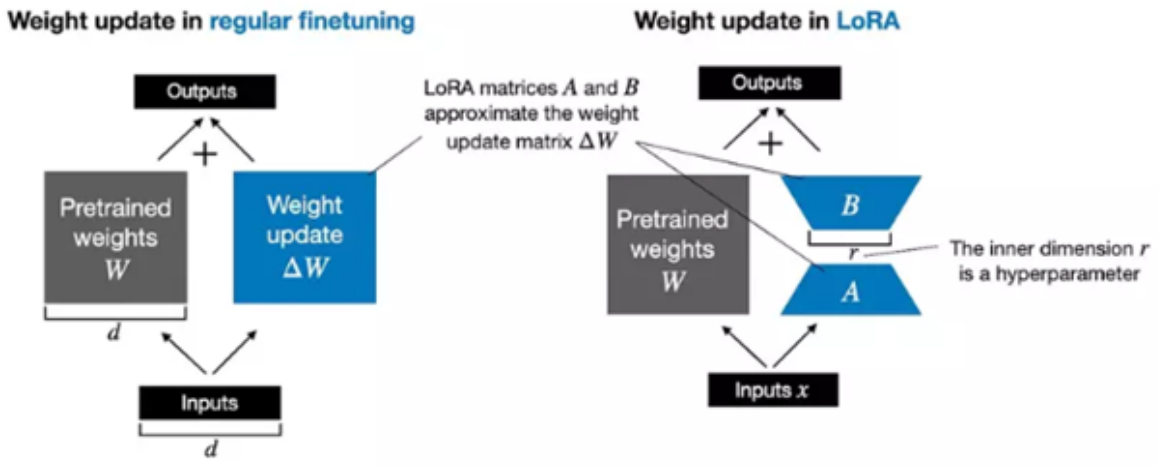
3.3.1. Full Fine-tuning

Phương pháp này cập nhật toàn bộ tham số của mô hình tiền huấn luyện trong quá trình huấn luyện lại. Điều này giúp mô hình **thích nghi tốt nhất** với đặc điểm dữ liệu mới. Tuy nhiên, đối với các mô hình quy mô lớn, fine-tuning đầy đủ rất **tốn tài nguyên** (bộ nhớ GPU, thời gian huấn luyện) và dễ gặp hiện tượng “quên đi” kiến thức đã học trước đó khi đào tạo lại trên tập dữ liệu nhỏ hơn. Thực tế cho thấy khi mô hình tăng kích thước (ví dụ GPT-3 với 175 tỷ tham số), fine-tuning đầy đủ là không khả thi (chi phí bộ nhớ quá lớn). Điều này thúc đẩy việc tìm kiếm các phương pháp tinh chỉnh tiết kiệm tham số.

3.3.2. Low-Rank Adaptation (LoRA)

LoRA là một kỹ thuật hiệu quả để **tinh chỉnh tiết kiệm tham số**. Thay vì cập nhật trực tiếp ma trận trọng số lớn W trong mô hình, LoRA **khóa (freeze)** W và chỉ học hai ma trận phân rã hạng thấp A và B nhỏ hơn nhiều. Cụ thể, nếu W có kích thước **d x k**, ta chọn hạng r rất nhỏ (chẳng hạn r=8 hoặc 16). Khi đó B có kích thước **d x r** và A có kích thước **r x k**, sao cho sự thay đổi trọng số W = B x A Như vậy, số tham số cần huấn luyện là d x r + r x k, giảm rất lớn so với d x k.

Để dễ hình dung, hình dưới đây minh họa việc LoRA giữ nguyên trọng số gốc, thêm hai ma trận A,B với hạng thấp để tinh chỉnh, và sau đó gộp (merge) thành ma trận cuối cùng:



Nhờ LoRA, số lượng tham số trainable giảm **hàng chục đến hàng nghìn lần**, đồng thời tiết kiệm rất nhiều bộ nhớ GPU. Ví dụ, một thí nghiệm cho thấy LoRA có thể giảm tham số huấn luyện từ 175 tỷ (GPT-3) xuống khoảng 18 triệu, tiết kiệm đến 2/3 bộ nhớ GPU. Đáng lưu ý, LoRA không làm giảm độ chính xác của mô hình: nó đạt hiệu năng **tương đương hoặc thậm chí cao hơn** so với fine-tuning đầy đủ trên nhiều mô hình (RoBERTa, DeBERTa, GPT-2/3,…). Trong đề tài, kết quả thực nghiệm (theo slide) cũng cho thấy LoRA với rank nhỏ gần tiệm cận hiệu năng của full fine-tuning (ViT5 F1 ~0.73 so với 0.81 khi full-tune) – một đánh đổi có thể chấp nhận được để tiết kiệm tính toán.

Lợi ích chính của LoRA trong đề tài: giảm đáng kể số tham số cần cập nhật trong quá trình fine-tune, cho phép huấn luyện các mô hình lớn (như ViT5, BARTpho) trên phần cứng hạn chế. Kỹ thuật này giúp chúng tôi đạt gần hiệu suất tối đa với chi phí tính toán thấp hơn nhiều so với full fine-tuning thông thường. Có thể là một phương án đáng để cân nhắc khi thử nghiệm với bộ dataset lơn hơn hoặc sử dụng mô hình phức tạp hơn về sau

---

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Phương pháp đánh giá (Bổ sung chi tiết)

Do đặc thù của bộ dữ liệu NEU-ESC có sự mất cân bằng lớn giữa các lớp (ví dụ: nhãn *Neutral* chiếm 69.1% trong khi *Toxic* chỉ chiếm 2.6% [3]), việc sử dụng đơn lẻ độ chính xác (Accuracy) không phản ánh đúng hiệu năng của mô hình. Vì vậy, chúng tôi sử dụng tập hợp các chỉ số sau để đánh giá toàn diện:

4.1.1. Độ chính xác (Accuracy)

Đây là chỉ số cơ bản nhất, đo lường tỷ lệ số mẫu dự đoán đúng trên tổng số mẫu thực nghiệm.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Tuy nhiên, trong bối cảnh bài toán này, Accuracy chỉ mang tính tham khảo tổng quan. Một mô hình có thể đạt Accuracy rất cao chỉ bằng cách dự đoán tất cả các mẫu về lớp đa số (Neutral), nhưng lại hoàn toàn thất bại trong việc nhận diện các lớp quan trọng như Toxic hay Spam.

4.1.2. Precision (Độ chính xác dự báo) và Recall (Độ phủ)

Để đánh giá sâu hơn vào từng lớp dữ liệu, đặc biệt là các lớp thiểu số, chúng tôi xem xét hai khía cạnh:

- Precision (P): Cho biết trong số các mẫu mô hình dự đoán là lớp C, bao nhiêu phần trăm là chính xác. Chỉ số này quan trọng để tránh báo động giả (False Positive).

$$Precision = \frac{TP}{TP + FP}$$

- Recall (R): Cho biết trong số các mẫu thực tế thuộc lớp C, mô hình đã tìm ra được bao nhiêu phần trăm. Đây là chỉ số quan trọng đối với các nhãn tiêu cực (Negative/Toxic), nơi việc bỏ sót (False Negative) gây hậu quả lớn hơn việc nhầm lẫn.

$$Recall = \frac{TP}{TP + FN}$$

4.1.3. F1-Score (Macro và Weighted)

F1-Score là trung bình điều hòa giữa Precision và Recall, giúp cân bằng giữa độ chính xác và độ phủ.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Trong báo cáo này, chúng tôi tập trung vào:

- **Weighted-F1:** Tính F1 cho từng nhãn, sau đó lấy trung bình cộng có trọng số dựa trên số lượng mẫu (support) của nhãn đó trong tập dữ liệu.
    - *Ý nghĩa:* Chỉ số này phản ánh hiệu năng tổng thể của hệ thống trên toàn bộ dữ liệu thực tế, nơi các lớp phổ biến (như *Neutral, Academic*) xuất hiện nhiều hơn.

4.1.4. Đánh giá Đa nhiệm (Multi-task Evaluation)

Vì mô hình thực hiện đồng thời hai tác vụ, hiệu năng được đo lường độc lập cho từng đầu ra:

1. **Sentiment Metrics:** Đánh giá trên 4 nhãn (Neutral, Positive, Negative, Toxic).
2. **Topic Metrics:** Đánh giá trên 10 nhãn chủ đề

4.2. Kết quả và nhận xét

Bảng 1: So sánh Kết quả Phân loại Cảm xúc (Sentiment Analysis)

Tên Mô Hình & Cấu Hình	Phương Pháp	Accuracy	Recall (Weighted)	F1-Score (Weighted)
PhoBERT-base-v2	**Full Fine-tune**	**82.16%**	**0.82**	**0.82**
PhoBERT-base-v2	**MLM**	**80.84%**	**0.81**	**0.81**
PhoBERT-base-v2	**SMART**	**81.26%**	**0.81**	**0.82**

PhoBERT-base-v2	**MLM + SMART**	**80.31%**	**0.80**	**0.81**
XLM-RoBERTa	**Full Fine-tune**	**79.80%**	**0.80**	**0.80**
XLM-RoBERTa	**MLM**	**81.63%**	**0.82**	**0.82**
XLM-RoBERTa	**SMART**	**80.89%**	**0.81**	**0.81**
XLM-RoBERTa	**MLM + SMART**	**81.69%**	**0.82**	**0.82**
VisoBERT	**Full Fine-tune**	**81.70%**	**0.82**	**0.82**
VisoBERT	**MLM**	**80.96%**	**0.81**	**0.81**
VisoBERT	**SMART**	**81.99%**	**0.82**	**0.82**
VisoBERT	**MLM + SMART**	**82.19%**	**0.82**	**0.82**
ViT5	**Full Fine-tune**	**80.96%**	**0.81**	**0.81**
Bartpho-word	**Full Fine-tune**	**79.16%**	**0.79**	**0.80**

ViT5	**LoRA (PEFT)**	**73.11%**	**0.73**	**0.75**
Bartpho-word	**LoRA**	**75.23%**	**0.77**	**0.76**

Nhận xét:

- PhoBERT dẫn đầu ở mọi chỉ số trong bài toán cảm xúc với 82.16% độ chính xác, cho thấy khả năng hiểu ngữ nghĩa ngắn và cảm xúc của tiếng Việt rất tốt.
- ViT5 Full bám rất sát nút (80.96%).
- Kỹ thuật MLM + SMART giúp cải thiện XLM-RoBERTa và VisoBERT, nhưng lại làm giảm hiệu suất của PhoBERT
- Trong một số trường hợp, dùng SMART hoặc MLM đơn lẻ tốt hơn dùng MLM + SMART
- ViT5 LoRA có sự sụt giảm đáng kể về Recall (chỉ 0.73), tức là mô hình bỏ sót khá nhiều trường hợp đúng so với bản Full.
- Nhóm mô hình Encoder-only (PhoBERT, VisoBERT) nhìn chung ch**o kết quả ổn định và cao hơn** nhóm Encoder-Decoder (ViT5, Bartpho)

Bảng 2: So sánh Kết quả Phân loại Chủ đề (Topic Classification)

Tên Mô Hình & Cấu Hình	Phương Pháp	Accuracy	Recall (Weighted)	F1-Score (Weighted)
PhoBERT-base-v2	**Full Fine-tune**	**76.61%**	**0.77**	**0.77**
PhoBERT-base-v2	**MLM**	**76.82%**	**0.77**	**0.77**
PhoBERT-base-v2	**SMART**	**77.35%**	**0.77**	**0.78**

PhoBERT-base-v2	**MLM + SMART**	**75.00%**	**0.75**	**0.76**
XLM-RoBERTa	**Full Fine-tune**	**77.09%**	**0.77**	**0.77**
XLM-RoBERTa	**MLM**	**77.85%**	**0.78**	**0.78**
XLM-RoBERTa	**SMART**	**77.97%**	**0.78**	**0.78**
XLM-RoBERTa	**MLM + SMART**	**78.24%**	**0.78**	**0.79**
VisoBERT	**Full Fine-tune**	**76.68%**	**0.77**	**0.77**
VisoBERT	**MLM**	**77.53%**	**0.78**	**0.78**
VisoBERT	**SMART**	**77.79%**	**0.78**	**0.78**
VisoBERT	**MLM + SMART**	**79.01%**	**0.79**	**0.79**
BartPho	**Full Fine-tune**	**70%**	**0.69**	**0.71**
ViT5	**Full Fine-tune**	**75.99%**	**0.76**	**0.76**

Bartpho-word	**Full Fine-tune**	**75.44%**	**0.75**	**0.76**
ViT5	**LoRA (PEFT)**	**73.19%**	**0.73**	**0.74**

Nhận xét:

- VisoBERT (MLM + SMART) có độ chính xác cao nhất với 79.01%
- Trái ngược với bài toán cảm xúc, XLM-RoBERTa ở bài toán này hoạt động hiệu quả hơn PhoBERT (78.24% so với 77.35%), cho thấy lợi thế của mô hình đa ngôn ngữ khi xử lý các chủ đề đa dạng
- Các kỹ thuật tối ưu (MLM, SMART) giúp VisoBERT tăng mạnh hiệu suất (từ 76.68% lên 79.01%), mức cải thiện ấn tượng hơn nhiều so với các mô hình khác
- Ở bài toán chủ đề phức tạp hơn (nhiều nhãn hơn), khoảng cách giữa các mô hình Full Fine-tune (PhoBERT, ViT5, Bartpho) bị thu hẹp lại, chênh lệch Accuracy chỉ chưa đến 1.2%.
- Điều này cho thấy với bài toán khó, kiến trúc Encoder-Decoder (như Bartpho, ViT5) bắt đầu phát huy tác dụng nhờ khả năng xử lý ngữ cảnh rộng hơn, dù PhoBERT vẫn nhỉnh hơn một chút.
- ViT5 LoRA vẫn thấp nhất nhưng khoảng cách với bản Full ở bài toán này (73.19% vs 75.99%) nhỏ hơn so với bài toán Sentiment, chứng tỏ LoRA vẫn học được các đặc trưng chủ đề khá ổn định.

4.3. Phân tích một số mẫu thực tế

Best case:

“à chắc var nhiều quá đâm ra ngáo quyền lực con mẹ nó rồi rồi chứ gì bảo sao nay ăn nói...”

Expect: Toxic, Personal Affair

Pred: Toxic, Personal Affair

- **Câu này chứa các đặc trưng ngôn ngữ (features) cực mạnh của nhãn Toxic mà mô hình rất dễ học được:**
- **Từ ngữ thô tục (Profanity):** Cụm từ "con mẹ nó" là một tín hiệu mạnh (strong feature). Hầu hết các mô hình phân loại cảm xúc, kể cả cơ bản nhất, đều sẽ đánh trọng số cực cao cho các từ chửi thề này để gán nhãn Toxic/Negative.
- **Từ lóng mang sắc thái tiêu cực (Negative Slang):** Từ "ngáo" (trong "ngáo quyền lực") là từ lóng phổ biến trên mạng xã hội dùng để chỉ trích sự ảo tưởng, hành xử không bình thường. Các mô hình như ViSoBERT (được huấn luyện trên dữ liệu

mạng xã hội Facebook, TikTok...) đặc biệt nhạy bén với các từ vựng này hơn là các mô hình chỉ học trên báo chí chính thống.

- Mô hình định danh chính xác Personal Affair (Chuyện cá nhân/Tâm sự) vì các lý do sau:

- **Đối tượng hướng tới:** Câu văn tập trung nhận xét về hành vi, thái độ của một cá nhân cụ thể ("ăn nói", "ngáo quyền lực"). Đây là đặc trưng cốt lõi của topic Personal Affair - thường xoay quanh drama, xung đột giữa các cá nhân hoặc nhận xét về tính cách.
- **Loại trừ các Topic khác:** Câu văn hoàn toàn vắng bóng các từ khóa dễ gây nhiễu thuộc các chủ đề lớn khác:
    - Không có từ khóa học đường (thi, điểm, môn, tín chỉ) → Loại Academic.
    - Không có từ khóa dịch vụ (gửi xe, thư viện, bảo vệ) → Loại Service.
    - Không bàn về vấn đề xã hội vĩ mô → Loại Social.
- **Từ khóa "VAR":** "Var" ở đây là tiếng lóng (xuất phát từ bóng đá, nghĩa là kiểm tra lại/soi xét). Trong ngữ cảnh drama sinh viên (Confessions), "var" thường đi kèm với các câu chuyện xích mích cá nhân. Mô hình đã học được mối tương quan này (Correlation) trong quá trình huấn luyện.

Worst case:

“djtme học ở ute xong muốn nghỉ luôn .”

Expect: Toxic, other

Pred: Neutral, academic

- **Khả năng xử lý từ lóng (Teencode/Slang**)

- Từ **"djtme**" là một biến thể **teencode** (viết tắt/sai chính tả) của từ chửi thề.
- Mô hình đã bị "đánh lừa" bởi các từ khóa liên quan trực tiếp đến trường học xuất hiện trong câu.
- **Từ khóa:** Trong câu có từ **"học"** và **"ute" (tên trường/viết tắt).**
- **Cơ chế:** Các mô hình học sâu (Deep Learning) thường bám vào các đặc trưng từ vựng mạnh (strong lexical features). Khi thấy từ "học", mô hình có xu hướng dự đoán ngay lập tức đây là chủ đề Academic (Học tập) thay vì xem xét ngữ cảnh tổng thể là một câu than vãn (thuộc chủ đề Other).
- **Thống kê:** Trong tập dữ liệu, Topic Academic chiếm tỷ trọng lớn thứ 2 (31.9%), chứa rất nhiều từ vựng liên quan đến việc học, khiến mô hình thiên vị nhãn này khi thấy từ khóa liên quan.

Worst case:

“lại kinh rồi . dừng khinh nhau lúc cơ hàn đến lúc cờ tàn tốt lại đuổi xe .”

Expect: Neutral, Other

Pred: Negative, Social

- **Mô hình dự đoán Negative thay vì Neutral do bị chi phối bởi các từ khóa mang sắc thái mạnh:**
- **Từ khóa "mồi":** Câu chứa các từ vựng đơn lẻ mang nghĩa tiêu cực rõ rệt như "khinh" (coi thường, khinh miệt), "kinh" (trong ngữ cảnh này là mỉa mai thái độ), "cơ hàn" (nghèo khổ).
- **Hạn chế ngữ dụng (Pragmatics):**
    - Câu văn thực chất là một lời khuyên hoặc triết lý sống (dạng Proverb/Thành ngữ), thường được gán nhãn Neutral (Trung tính) trong các bộ dữ liệu chuẩn.
    - Tuy nhiên, mô hình (model) thiên về việc bắt các đặc trưng từ vựng bề mặt (surface features). Khi thấy cụm từ "khinh nhau" và giọng điệu mỉa mai ("lại kinh rồi"), mô hình kích hoạt nhãn Negative mà không hiểu được ý nghĩa răn dạy đằng sau câu nói.
- **Mô hình dự đoán Social thay vì Other do nội dung câu nói liên quan chặt chẽ đến tương tác xã hội:**
- **Tín hiệu "Social":** Câu nói bàn về cách đối nhân xử thế giữa người với người ("đừng khinh nhau"), một chủ đề rất gần với định nghĩa của Social (Xã hội/Đời sống). Điều này cho thấy mô hình thực tế đã "hiểu" được ngữ cảnh giao tiếp xã hội của câu.
- **Định nghĩa nhãn "Other":** Trong bộ dữ liệu, nhãn Other chiếm tỷ trọng lớn nhất (43.7%). Đây là lớp "tạp" chứa các nội dung không rõ ràng, bao gồm cả những câu cảm thán, chém gió, hoặc triết lý vu vơ không thuộc về một sự kiện xã hội cụ thể.
- **Lý do sai:** Việc gán nhãn thực tế (Ground Truth) là Other có thể do quy ước của người gán nhãn coi các câu triết lý chung chung là Other. Tuy nhiên, mô hình lại bắt được tính chất "xã hội" (quan hệ con người) nên phân loại vào Social. Đây là một trường hợp "sai nhưng có lý" của mô hình**.**
- **Thách thức với Thành ngữ và Mỉa mai (Sarcasm & Idioms):**
- **Mỉa mai:** Cụm ***"lại kinh rồi"*** là một khẩu ngữ mang tính mỉa mai (sarcasm). Các mô hình ngôn ngữ thường gặp khó khăn trong việc phân biệt giữa tiêu cực thực sự (chửi bới) và mỉa mai (trêu đùa/bình luận), dẫn đến xu hướng gán nhãn Negative cho an toàn.

4.4. Thảo luận kết quả phân loại cảm xúc

Kết quả thực nghiệm cho thấy PhoBERT đạt hiệu năng cao nhất trong bài toán phân loại cảm xúc. Điều này có thể được lý giải bởi việc PhoBERT được tiền huấn luyện chuyên biệt cho tiếng Việt với chiến lược tách từ rõ ràng, giúp mô hình nắm bắt tốt các biểu thức cảm xúc ngắn và giàu sắc thái.

Trong khi đó, ViT5 và BartPho thể hiện hiệu năng cạnh tranh, cho thấy kiến trúc Encoder–Decoder không hề thua kém trong các bài toán phân loại, dù ban đầu được thiết kế cho nhiệm vụ sinh văn bản. Tuy nhiên, khi áp dụng LoRA cho ViT5, hiệu năng suy giảm đáng kể, đặc biệt ở Recall. Điều này cho thấy trong bài toán cảm xúc, không gian biểu diễn cần điều chỉnh tương đối lớn để thích nghi, và giả định hạng thấp của LoRA có thể trở thành yếu tố giới hạn.

4.5. Thảo luận kết quả phân loại chủ đề

Ở bài toán phân loại chủ đề với số lượng nhãn lớn hơn, khoảng cách hiệu năng giữa các mô hình Full Fine-tune bị thu hẹp. Điều này phản ánh bản chất phức tạp của tác vụ, nơi việc hiểu ngữ cảnh tổng thể quan trọng hơn so với việc nhận diện các tín hiệu cảm xúc cục bộ.

Đáng chú ý, ViT5 LoRA cho thấy mức suy giảm hiệu năng ít hơn so với bài toán cảm xúc. Kết quả này gợi ý rằng các đặc trưng chủ đề có xu hướng ổn định hơn trong không gian biểu diễn, và do đó phù hợp hơn với giả định cập nhật hạng thấp của LoRA.

4.6. Tổng hợp và phân tích so sánh

Từ các kết quả trên, có thể nhận thấy rằng không tồn tại một kiến trúc tối ưu tuyệt đối cho mọi tác vụ. Các mô hình Encoder-only tỏ ra vượt trội trong việc khai thác các tín hiệu ngữ nghĩa cục bộ, trong khi các mô hình Seq2Seq phát huy lợi thế khi xử lý ngữ cảnh rộng và mối quan hệ giữa các nhãn.

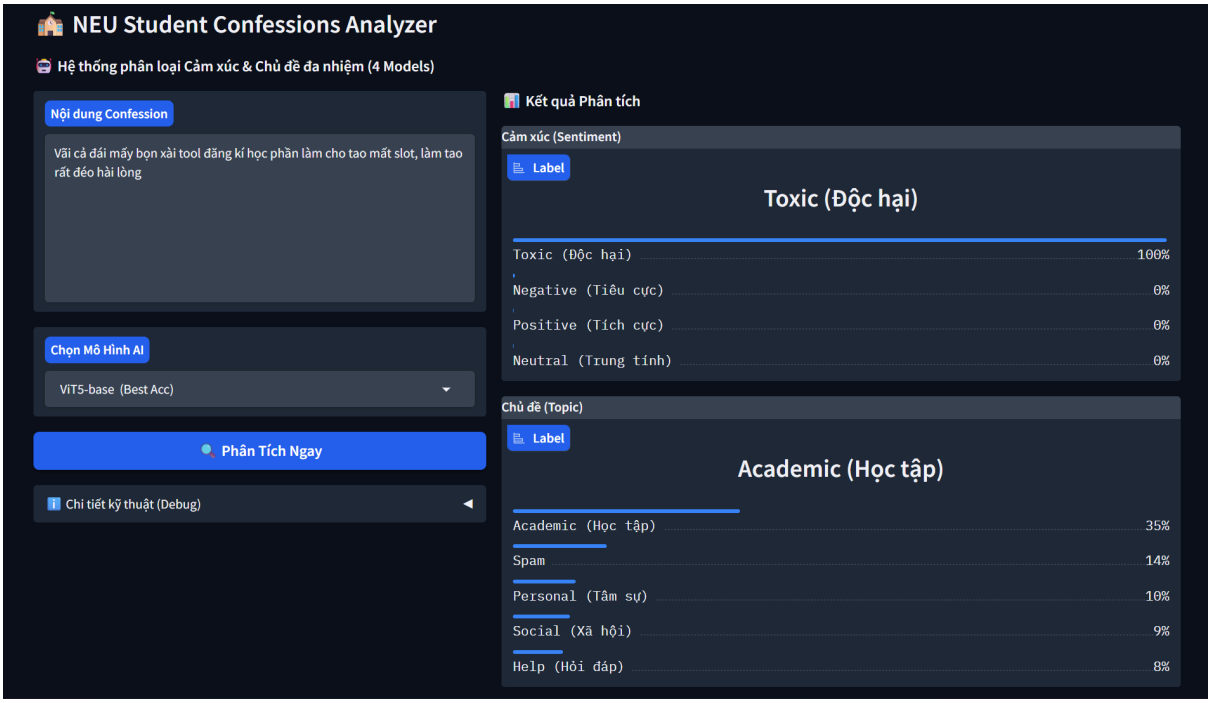
Việc kết hợp học đa nhiệm, tác vụ phụ MLM và các kỹ thuật điều chuẩn hiện đại đã góp phần nâng cao đáng kể độ ổn định và khả năng tổng quát hóa của mô hình, đặc biệt trong bối cảnh dữ liệu tiếng Việt hạn chế.

4.7. Cài đặt và demo:

Sử dụng python và các thư viện hỗ trợ như transformer, peft,... cho quá trình huấn luyện và fine tune

Sử dụng tài nguyên bên thứ 3 như kaggle và collab

Demo nhanh bằng thư viện gradio



CHƯƠNG 5: KẾT LUẬN

Nghiên cứu đã đề xuất và kiểm chứng thành công một khung phương pháp luận hoàn chỉnh cho bài toán phân loại đa nhiệm cảm xúc và chủ đề trên văn bản tiếng Việt. Các đóng góp chính bao gồm việc chứng minh tính hiệu quả của kiến trúc chia sẻ tham số cứng kết hợp với các mô hình ngôn ngữ tiếng Việt; áp dụng thành công các kỹ thuật tối ưu hóa hiện đại như LoRA và SMART để giải quyết bài toán tài nguyên và độ ổn định; và đề xuất hàm mất mát tổng hợp để xử lý triệt để vấn đề mất cân bằng dữ liệu.

Hướng phát triển tiếp theo của đề tài sẽ tập trung vào việc mở rộng mô hình để xử lý thêm các tác vụ trích xuất thông tin khác như nhận diện thực thể, đồng thời thử nghiệm trên các kiến trúc mô hình ngôn ngữ lớn thế hệ mới để nâng cao hơn nữa khả năng hiểu và sinh ngôn ngữ.

PHỤ LỤC

Bảng phân tích hoạt động của mô hình đối với ngữ liệu

STT	**Văn bản đầu vào**	**Nhãn thực tế**	**Nhãn dự đoán**	**Phân tích nguyên nhân**
1	không mua này . giá máy mua hàng cũ . máy apple ngừng thức... yên tâm khoản tổng kết thì...	NEGATIVE, SPAM	NEUTRAL, SPAM	**Dự đoán sai ở nhãn cảm xúc**: nguyên nhân có thể là do nhiễu từ khóa. Văn bản chứa nhiều từ vựng mang sắc thái tích cực giả tạo của tin rác (spam) như "ok", "yên tâm", "pin tốt". Mô hình tập trung quá nhiều vào các đặc trưng cục bộ này, dẫn đến việc trung hòa nhãn cảm xúc tiêu cực tổng thể.

2	asus mua lê nghị chẹo rồi đi học đi oke game lòi mắt xịn ngon được liên minh autocad...	POSITIVE, OTHER	POSITIVE, OTHER	**Dự đoán đúng**: Mô hình nhận diện chính xác các từ lóng và từ vựng biểu thị cảm xúc tích cực đặc trưng của miền dữ liệu) như "oke", "xịn", "ngon".
3	kết quả giờ chị hói con mẹ nó luôn .	TOXIC, OTHER	NEGATIVE, OTHER	**Dự đoán sai ở nhãn cảm xúc**: Nguyên nhân là do nhầm lẫn lớp. Mô hình gặp khó khăn trong việc phân biệt ranh giới giữa *Negative* (Tiêu cực) và *Toxic* (Độc hại). Cụm từ "con mẹ nó" trong ngữ cảnh này đóng vai trò là từ nhấn mạnh cho trạng thái tiêu cực hơn là một lời công kích cá nhân trực tiếp, gây ra sự lệch nhãn.
4	à chắc var nhiều quá đâm ra ngáo quyền lực con mẹ nó rồi rồi chứ gì bảo sao nay ăn nói...	TOXIC, PERSONAL AFFAIR	TOXIC, PERSONAL AFFAIR	**Dự đoán đúng (True Positive):** Văn bản chứa các cụm từ mang tính công kích cá nhân mạnh mẽ như "ngáo quyền lực", "con mẹ nó", "ăn nói như thằng mới bú đá xong". Mô hình đã nhận diện chính xác tính chất độc hại (Toxic) và chủ đề liên quan đến vấn đề cá nhân (Personal Affair).

Bảng phân tích nhãn ban đầu của ngữ liệu

STT	Văn bản đầu vào	Nhãn cảm xúc	Nhãn topic	Phân tích & giải thích
1	inbox vùng kín soạn cho 7749 bài tế .	NEUTRAL	SPAM	Cảm xúc: Trung tính. Đây là một lời chào mời dịch vụ mang tính chất giao dịch thương mại. Người viết chỉ đưa ra thông tin về hành động ("inbox", "soạn") mà không bộc lộ thái độ vui, buồn hay giận dữ. Chủ đề: Spam. Văn bản chứa từ khóa đặc trưng của tin nhắn rác hoặc quảng cáo dịch vụ viết thuê ("inbox", "7749 bài tế").
2	nếu đậu phương thức 5 xét tuyển thì đăng ký thi tt chất lượng cao chọn đối tượng nào ạ .	NEUTRAL	NEWS	Cảm xúc: Trung tính. Đây là câu nghi vấn nhằm mục đích tìm kiếm thông tin về thủ tục hành chính. Câu văn khách quan, không chứa từ ngữ biểu cảm. Chủ đề: News. Nội dung xoay quanh quy chế tuyển sinh và đào tạo ("xét tuyển", "đăng ký thi", "chất lượng cao").

3	em xin chào các anh chị em em là sinh viên vừa tốt nghiệp... xin đi học ở phụ sản trung ương...	NEUTRAL	ACADEMIC	Cảm xúc: Trung tính. Văn bản là một bài trình bày hoàn cảnh và xin lời khuyên nghề nghiệp một cách lịch sự, từ tốn. Mặc dù có từ "mong", "cảm ơn" nhưng sắc thái chủ đạo là nghiêm túc. Chủ đề: Academic. Văn bản chứa nhiều thực thể liên quan đến học thuật và y khoa ("sinh viên", "tốt nghiệp", "giấy phép hành nghề", "viện sản").
4	ngủ trưa trưa dậy uống lọc chiều dậy sôi không không tiết kiệm .	NEUTRAL	OTHER	Cảm xúc: Trung tính. Câu văn tường thuật lại thói quen sinh hoạt cá nhân hàng ngày một cách đơn điệu, không mang hàm ý đánh giá hay cảm xúc cá nhân. Chủ đề: Other. Nội dung tản mạn về sinh hoạt đời thường, không thuộc các chủ đề cụ thể khác.

5	ké taekwondo size ạ .	NEUTRAL	SERVICE	Cảm xúc: Trung tính. Đây là câu nói ngắn gọn dùng trong giao dịch mua bán/trao đổi (ké đơn hàng). Mục đích thuần túy là thông tin về kích cỡ ("size"), không biểu lộ cảm xúc. Chủ đề: Service. Từ khóa "ké", "size" thường xuất hiện trong ngữ cảnh mua bán, order hàng hóa hoặc dịch vụ.
6	parttime ưu tiên học sinh sinh viên xoay ca linh hoạt không yêu cầu kinh nghiệm...	NEUTRAL	JOBS	Cảm xúc: Trung tính. Văn bản là thông báo tuyển dụng tiêu chuẩn, liệt kê các yêu cầu và quyền lợi một cách khách quan, thông tin dạng liệt kê. Chủ đề: Jobs. Chứa mật độ cao các từ vựng chuyên ngành tuyển dụng ("parttime", "xoay ca", "kinh nghiệm", "ưu tiên").

7	tóm tắt cho ai chưa đọc chàng trai bị bạn gái chê nghèo nên đau đầu viết confession...	NEUTRAL	PERSONAL	Cảm xúc: Trung tính. Mặc dù câu chuyện được nhắc đến có thể buồn ("bị chê nghèo"), nhưng người viết đang đóng vai trò người kể chuyện/tóm tắt lại sự việc một cách khách quan, không bày tỏ quan điểm riêng. Chủ đề: Personal. Nội dung đề cập đến chuyện tình cảm cá nhân, tâm sự ("bạn gái", "confession", "hồi tưởng").
8	đừng nản . đam mê học hành nghiêm túc qua ... chúc thành công .	NEUTRAL	SOCIAL	Cảm xúc: Trung tính (thiên hướng tích cực nhẹ). Dù có từ "chúc thành công", nhưng tổng thể văn bản là một bài nghị luận dài, phân tích lý lẽ về đạo đức và pháp luật. Giọng văn mang tính giáo dục, khuyên răn điềm đạm hơn là bộc lộ cảm xúc mạnh. Chủ đề: Social. Văn bản bàn luận rộng về các vấn đề xã hội như "luật khám chữa bệnh", "đạo đức nghề nghiệp", "sự phát triển xã hội".

9	rút kinh nghiệm nhé mấy bạn .	NEUTRAL	HELP	Cảm xúc: Trung tính. Đây là câu cầu khiến mang tính nhắc nhở nhẹ nhàng. Không có từ ngữ chỉ trích gay gắt hay khen ngợi nồng nhiệt. Chủ đề: Help. Mục đích của câu là đưa ra lời khuyên, cảnh báo giúp người khác tránh sai lầm ("rút kinh nghiệm").
10	danh sách tham gia chào tân neu nyf .	NEUTRAL	CLUB	Cảm xúc: Trung tính. Văn bản chỉ là một tiêu đề hoặc thông báo về một tài liệu/danh sách, hoàn toàn mang tính thông tin. Chủ đề: Club. Chứa tên các sự kiện và tổ chức đội nhóm sinh viên ("chào tân", "neu", "nyf").
11	mê xờ tít lunn .	POSITIVE	SPAM	Cảm xúc: Tích cực. Sử dụng từ lóng "mê xờ tít" (rất mê) để diễn tả sự thích thú cực độ. Chủ đề: Spam. Câu quá ngắn, thường thấy trong các bình luận "seeding" hoặc tương tác ảo để tăng

				view, không mang nội dung cụ thể.
12	tháng 9 này em phải đến neu nhé chúc mừng các sĩ tử đã hoàn thành xuất sắc...	POSITIVE	NEWS	Cảm xúc: Tích cực. Thể hiện rõ qua các cụm từ chúc tụng, động viên: "chúc mừng", "xuất sắc", "hẹn gặp". Chủ đề: News. Thông tin liên quan đến sự kiện nhập học và kỳ thi tốt nghiệp THPT quốc gia.
13	thi đi xã vui lắm không pc lĩnh vực pháp bệnh viện công an...	POSITIVE	ACADEMIC	Cảm xúc: Tích cực. Người viết trực tiếp đánh giá trải nghiệm là "vui lắm", khuyến khích người khác tham gia. Chủ đề: Academic/Jobs. Đề cập đến việc thi cử, văn bằng hai và các đơn vị đào tạo/công tác (học viện an ninh).
14	ủng hộ em học nhé .	POSITIVE	OTHER	Cảm xúc: Tích cực. Từ "ủng hộ" thể hiện thái độ đồng tình, khích lệ người nghe. Chủ đề: Other. Câu nói giao tiếp xã giao thông thường,

				ủng hộ một quyết định cá nhân.
15	xôi là món ngon nhất .	POSITIVE	SERVICE	Cảm xúc: Tích cực. Sử dụng tính từ so sánh nhất "ngon nhất" để khen ngợi món ăn. Chủ đề: Service. Review/đánh giá về sản phẩm ẩm thực (xôi).
16	chẳng khoa học kỹ thuật vừa . khoa học kỹ thuật lĩnh vực nhau...	POSITIVE	JOBS	Cảm xúc: Tích cực. Người viết có ý đề cao sự bình đẳng hoặc vẻ đẹp của các lĩnh vực khoa học kỹ thuật, dù câu văn hơi gãy gọn. Chủ đề: Jobs/Academic. Nhắc nhiều đến "khoa học kỹ thuật", "ngành", "lĩnh vực".
17	chúc mừng em trần minh anh nam định nhé .	POSITIVE	PERSONAL	Cảm xúc: Tích cực. Hành động "chúc mừng" trực tiếp thể hiện niềm vui chia sẻ với người khác. Chủ đề: Personal. Nhắc đến tên riêng và địa danh

				cụ thể, mang tính chất giao tiếp cá nhân.
18	svbk tham gia công kiến covid svbk đi ngỡ kỉ niệm đẹp tuyệt vời...	POSITIVE	SOCIAL	Cảm xúc: Tích cực. Sử dụng hàng loạt tính từ chỉ cảm xúc mạnh và tốt đẹp: "tuyệt vời", "kỉ niệm đẹp". Chủ đề: Social. Kể về các hoạt động tình nguyện, văn nghệ mang tính cộng đồng của sinh viên Bách Khoa.
19	top podcast phát triển bản thân bạn nên biết bên cạnh sách...	POSITIVE	HELP	Cảm xúc: Tích cực. Lan tỏa giá trị tích cực ("thông điệp tích cực", "chữa lành"), khuyên người khác làm điều tốt. Chủ đề: Help. Chia sẻ kiến thức, tài nguyên (podcast) để giúp người khác phát triển bản thân.
20	câu lạc bộ vui ui câu lạc bộ vui kiểu . đấy câu lạc bộ lập câu lạc bộ...	POSITIVE	CLUB	Cảm xúc: Tích cực. Lặp lại từ "vui" nhiều lần để nhấn mạnh không khí hào hứng. Chủ đề: Club. Nội dung xoay quanh hoạt động và

				không khí của câu lạc bộ sinh viên.
21	mình muốn gửi tới các bạn ai đang có nhu cầu xin việc... bọn lừa đảo...	NEGATIVE	SPAM	Cảm xúc: Tiêu cực. Người viết thể hiện sự bức xúc và cảnh giác cao độ trước hành vi xấu ("giả tạo", "lừa đảo"). Chủ đề: Spam. Cảnh báo về các tin rác, lừa đảo tuyển dụng (scam) trên mạng.
22	viết đẳng khoa học trao giải thưởng tạ quang bửu . xu cưỡng ta mải đếm...	NEGATIVE	NEWS	Cảm xúc: Tiêu cực. Giọng văn châm biếm, mỉa mai ("xu cưỡng", "trạng quỳnh", "láu cá") đối với thực trạng nghiên cứu khoa học. Chủ đề: News/Academic. Bàn luận về giải thưởng khoa học, công bố quốc tế (ISI/Scopus).
23	khoa giờ đào tạo như mớ rau cũng khá là hay đó chứ bs lỏm nhiều...	NEGATIVE	ACADEMIC	Cảm xúc: Tiêu cực. Sử dụng hình ảnh so sánh hạ thấp giá trị ("như mớ rau", "bs lỏm") để chê bai chất lượng đào tạo.

				Chủ đề: Academic. Phê phán quy trình đào tạo tại các trường y khoa/bệnh viện.
24	sao lại ghét cái kiểu làm sai xong khóc lóc ăn vạ thế nhỉ...	NEGATIVE	OTHER	Cảm xúc: Tiêu cực. Trực tiếp sử dụng động từ chỉ thái độ "ghét" và các từ ngữ mô tả hành vi xấu ("khóc lóc", "ăn vạ"). Chủ đề: Other. Phàn nàn về cách ứng xử trong cuộc sống, không gắn với một lĩnh vực chuyên môn cụ thể.
25	làm ổ khóa chống bị cậy ấy ạ mất 800 không xong sửa linh tinh...	NEGATIVE	SERVICE	Cảm xúc: Tiêu cực. Thể hiện sự thất vọng vì mất tiền mà dịch vụ kém ("không xong", "sửa linh tinh"). Chủ đề: Service. Phàn nàn về dịch vụ sửa chữa xe máy/khóa.

26	nafosted là cách để các nhà khoa học ra tăng thu nhập... bị thao túng...	NEGATIVE	JOBS	Cảm xúc: Tiêu cực. Dù có lập luận logic, nhưng người viết dùng các từ ngữ vạch trần mặt tối ("thao túng", "trốn nhiệm vụ", "ăn tiền 2 đầu"). Chủ đề: Jobs/Science. Tranh luận về cơ chế lương thưởng và tài trợ nghiên cứu khoa học.
27	thế mà chê ueb toàn chapboi .	NEGATIVE	PERSONAL	Cảm xúc: Tiêu cực. Từ "chê" thể hiện thái độ không hài lòng hoặc phản bác lại một định kiến xấu. Chủ đề: Personal. Liên quan đến hình ảnh cá nhân/nhóm sinh viên (trap boy/chapboi) của một trường đại học.
28	tôi phải tham gia nhóm này thì mới được bl à sao lại cực đoan hẹp hòi thế nhỉ...	NEGATIVE	SOCIAL	Cảm xúc: Tiêu cực. Người viết dùng các tính từ chỉ trích tính cách ("cực đoan", "hẹp hòi") và thể hiện sự chán nản ("bye bye", "ngán"). Chủ đề: Social. Phàn nàn về cách quản lý cộng

				đồng/nhóm xã hội trên mạng xã hội.
29	cảnh giác mọi người lừa không ạ . đầu ngõ mặc áo nắng...	NEGATIVE	HELP	Cảm xúc: Tiêu cực. Tâm lý lo lắng, bức xúc của người vừa gặp sự cố ("lừa", "đòi công lý"). Chủ đề: Help. Bài viết cảnh báo cộng đồng về thủ đoạn lừa đảo trên đường phố.
30	cho mình hỏi câu lạc bộ có đánh ở trường không ạ .	NEGATIVE	CLUB	Cảm xúc: Tiêu cực. Từ "đánh" gợi lên hành vi bạo lực hoặc xung đột, tạo sắc thái lo ngại hoặc thù địch. Chủ đề: Club. Câu hỏi liên quan trực tiếp đến hoạt động của câu lạc bộ.
31	các nhà cái cá cược bóng đá rất phổ biến... là xấu và vi phạm pháp luật	TOXIC	SPAM	Cảm xúc: Độc hại (Toxic). Dù câu văn có vẻ mô tả, nhưng nội dung cổ xúy hoặc đề cập đến hành vi "xấu", "vi phạm pháp luật" thường bị gắn nhãn Toxic trong kiểm duyệt nội dung. Chủ đề: Spam. Quảng cáo hoặc đề cập đến cờ bạc, cá

				độ (thường bị coi là spam độc hại).
32	vâng đau lắm nhưng đành phải làm thôi bác . tiếc là không như nước ngoài... báo rác...	TOXIC	NEWS	Cảm xúc: Độc hại (Toxic). Sự tiêu cực được đẩy lên cao trào với từ ngữ miệt thị nặng nề ("báo dởm", "báo rác"), thể hiện sự phẫn nộ tột độ. Chủ đề: News/Academic. Chỉ trích gay gắt nền báo chí và liêm chính học thuật.
33	năm trước ôn lên ôn xuống việt nam mà địt mẹ ra sóng ạ	TOXIC	ACADEMIC	Cảm xúc: Độc hại (Toxic). Sử dụng từ ngữ tục tĩu ("đ*t mẹ") để chửi thề khi nói về vấn đề thi cử. Chủ đề: Academic. Phàn nàn về việc ôn thi và đề thi văn học (tác phẩm "Sóng").
34	cái djt cò mẹ .	TOXIC	OTHER	Cảm xúc: Độc hại (Toxic). Văn bản chỉ bao gồm một câu chửi thề tục tĩu, không có nội dung thông tin.

				Chủ đề: Other. Không xác định được chủ đề cụ thể ngoài việc chửi bới.
35	...địt mẹ chắc chắn cao hơn bạn nè... bị ngu luôn đó...	TOXIC	SERVICE	Cảm xúc: Độc hại (Toxic). Bài viết chứa mật độ dày đặc các từ ngữ thô tục, xúc phạm trí tuệ và nhân phẩm người khác ("ngu", "đ*o", "lồng lộn"). Chủ đề: Service/Education. Mặc dù là bài chửi bới, nhưng nguyên nhân xuất phát từ sự bất mãn với dịch vụ đào tạo (học phí, cách tính điểm GPA).
36	công ty như lồn sếp thì hãm đồng nghiệp hai mặt...	TOXIC	JOBS	Cảm xúc: Độc hại (Toxic). Sử dụng từ ngữ tục tĩu ("như l*n", "hãm") để miêu tả môi trường làm việc. Chủ đề: Jobs. Review tiêu cực về công ty, sếp và đồng nghiệp.

37	trình độ ông này thì tao không quen biết... tư cách như lồn...	TOXIC	PERSONAL	Cảm xúc: Độc hại (Toxic). Công kích cá nhân bằng từ ngữ xúc phạm nặng nề ("tư cách như l*n"). Chủ đề: Personal. Đánh giá, phán xét tư cách đạo đức của một cá nhân cụ thể.
38	thì địt mẹ cải cách hơn năm rồi đấy như cái đầu buồi...	TOXIC	SOCIAL	Cảm xúc: Độc hại (Toxic). Chửi thề và dùng từ ngữ bộ phận sinh dục để so sánh, chê bai chính sách. Chủ đề: Social. Bàn luận về vấn đề cải cách xã hội nhưng với thái độ thù địch, vô văn hóa.
39	địt cụ cảm ơn đã gợi ý	TOXIC	HELP	Cảm xúc: Độc hại (Toxic). Mặc dù nội dung là "cảm ơn" (tích cực), nhưng việc chèn từ chửi thề ("đ*t cụ") ở đầu câu làm biến đổi tính chất câu thành thô lỗ, độc hại. Chủ đề: Help. Phản hồi lại một sự giúp đỡ/gợi ý từ người khác.

40	cần tham khảo thì inbox chị .	NEUTRAL	SPAM	Cảm xúc: Trung tính. Quay lại dạng câu trần thuật, đề nghị liên hệ để biết thêm thông tin, không mang cảm xúc. Chủ đề: Spam. Mẫu câu điển hình của các tài khoản bán hàng hoặc môi giới ("inbox chị").

TÀI LIỆU THAM KHẢO

[1] PhoBERT: Pre-trained language models for Vietnamese

[2] Unsupervised Cross-lingual Representation Learning at Scale

[3] ViSoBERT: A Pre-Trained Language Model for Vietnamese Social Media Text Processing

[4] ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation

[5] SMART: Robust and Efficient Fine-Tuning for Pre-trained Natural Language Models through Principled Regularized Optimization

[6] LoRA: Low-Rank Adaptation of Large Language Models

[7] NEU-ESC: A Comprehensive Vietnamese dataset for Educational Sentiment analysis and topic Classification toward multitask learning