# Multitask sentiment analysis and topic classfication

**NLP - CS221.Q13**


**Sinh viên thực hiện:**

**Nhóm AAA**

Trương Hoàng Đạt - 23520276

Lê Chí Hoàng - 23520520

**Giảng viên hướng dẫn:**

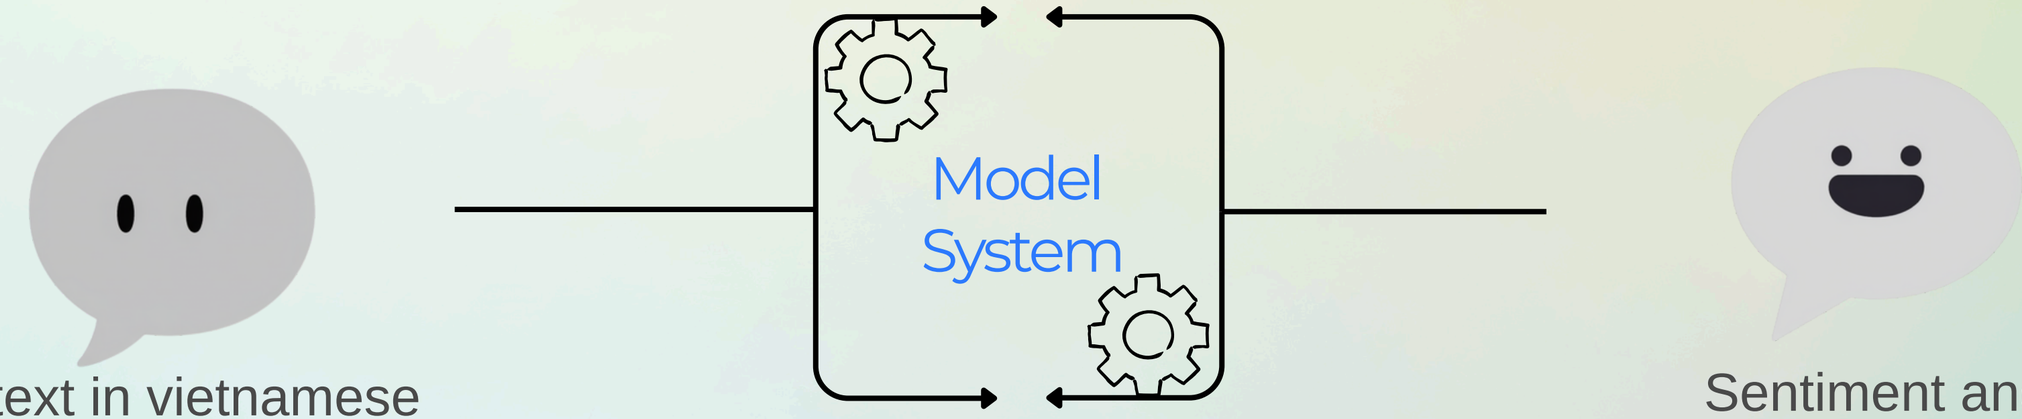
TS. Nguyễn Trọng Chỉnh

# Mục lục

1. Giới thiệu
2. Dataset
3. EDA
4. Mô hình baseline
5. Finetune LLM với các mô hình kiến trúc encoder-only (phoBERT, XLM-RoBERTa, VisoBERT)
6. Finetune LLM với các mô hình Seq2Seq (ViT5, BartPHO)

# 1 Giới thiệu

Phân loại cảm xúc và chủ đề đa nhiệm **(Multi-task Sentiment and Topic Classification)** là bài toán **đồng thời xác định cảm xúc** và **chủ đề** của một văn bản. Đây là bài toán kinh điển trong Xử lý ngôn ngữ tự nhiên, đặc biệt trong bối cảnh mạng xã hội ngày càng phát triển, các vấn đề liên quan đến tự động hóa việc nhận diện cảm xúc của người dùng theo từng chủ đề cụ thể sẽ giúp cho việc vận hành các nền tảng mạng xã hội tốt hơn và có hiệu quả hơn.




A text in vietnamese

**Input: "Thư viện trường mình sách nhiều mà còn mở cửa sớm nữa!"**

Sentiment and context of that text

**Output: Positive, Service**

**Trong đề tài này, nhóm thực nghiệm và so sánh hiệu quả khi finetune các mô hình thuộc kiến trúc Encoder-only và Encoder-Decoder trên bộ dữ liệu tiếng việt**

# 2 Dataset

**Tổng quan:**

**Nguồn gốc:** Dữ liệu được thu thập từ các diễn đàn, trang Confessions hoặc mạng xã hội liên quan đến sinh viên trường Đại học Kinh tế Quốc dân (NEU). Gồm 32,966 samples (train: 23,048 / val: 3,305 / test: 6,613).

**Mục tiêu:** Đây là bộ dữ liệu đa nhiệm (Multi-task), phục vụ đồng thời hai bài toán:

- Phân loại cảm xúc (Sentiment Analysis).
- Phân loại chủ đề (Topic Classification).

**Ngôn ngữ:** Tiếng Việt (bao gồm cả ngôn ngữ đời thường, teencode, viết tắt của sinh viên).

# 2 Dataset

**Thống kê label:**

| Label | Class |
|---|---|
| 0 | Neutral |
| 1 | Positive |
| 2 | Negative |
| 3 | Toxic |

**Sentiment Classification: 4 class**

# 2 Dataset

## Thống kê label:

Context Classification: 10 class

| Label | Class |
|---|---|
| 0 | Spam |
| 1 | News |
| 2 | Academic |
| 3 | Other |
| 4 | Service |
| 5 | Jobs |
| 6 | Personal |
| 7 | Social |
| 8 | Help |
| 9 | Club |

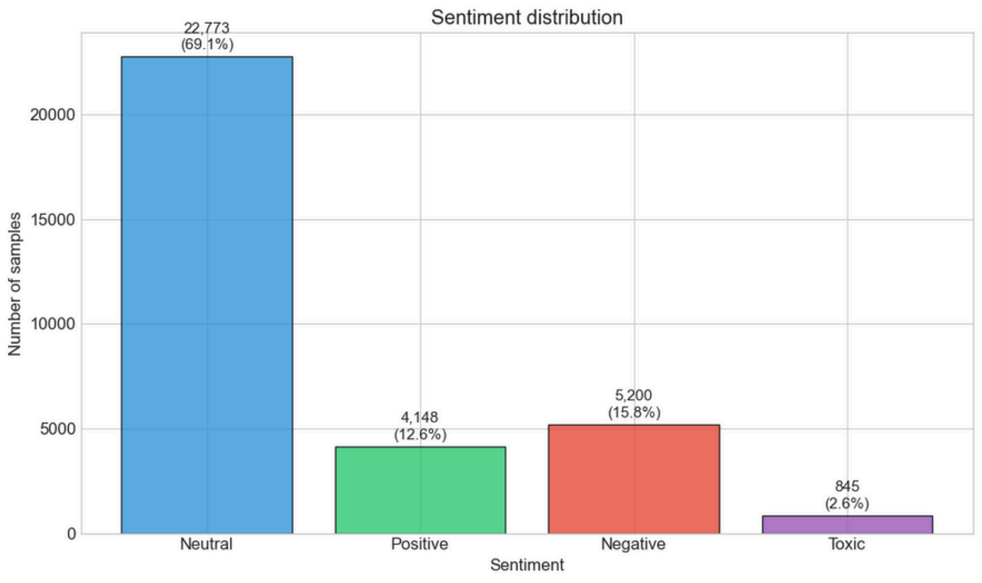
# 2 Dataset

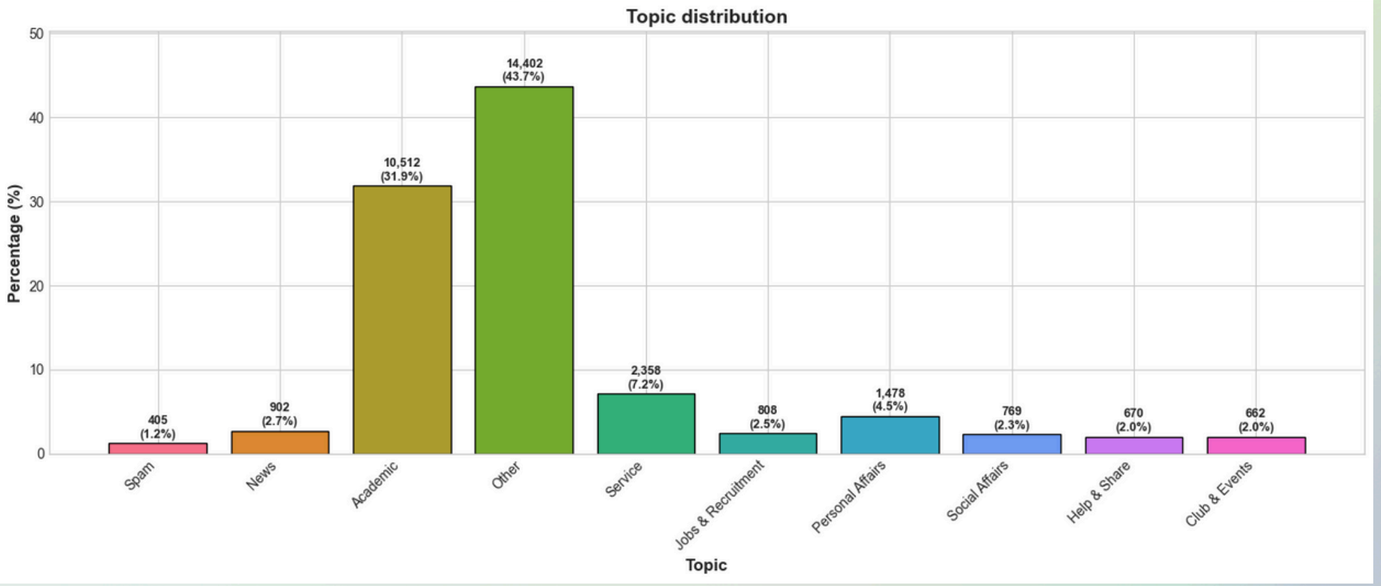
| text<br>string · *lengths*<br>3↔685 98.4% | sentiment<br>float64<br>0↔0.3 69.1% | classification<br>float64<br>2.7↔3.6 43.7% |
|---|---|---|
| phải đeo tai nghe vào cầm cái điện thoại ngang ra mới ôn chuẩn được . | 0 | 3 |
| cập nhật thời khóa biểu kỳ thu k k k check tâm hồn đẹp kỳ học nào . | 1 | 2 |
| có biết choi lien quan khong anh choi lien quan gioi lam . | 0 | 3 |
| bản tin không chủ nhật neu quý ii năm 2024 kính gửi quý thầy cô quý nhà khoa học . phòng quản lý khoa học trường đại học kinh tế quốc… | 0 | 1 |
| chuyển đi mà không báo trước cũng không tìm người thế vào thì bạn kia chấp nhận mất cọc hoi thà không báo rồi tìm người thế vào còn… | 0 | 3 |
| nắm tay nhau đi qua cầu nha đừng đi qua đường nữa . | 2 | 3 |
| nhuộm màu luôn phân vân . | 0 | 3 |
| em xin hỏi một chút là lịch thi cuối kì của bọn em ngày cuối là 12 1 k62 ạ thì sau đó bọn em có tiếp tục học chương trình học kì hai cho… | 0 | 2 |
| học lý thuyết lớp ghép a học thực hành chia lớp học à . | 0 | 2 |

Data card trên hugging face

# 3 EDA

Phân bố của các nhãn ở toàn bộ dữ liệu

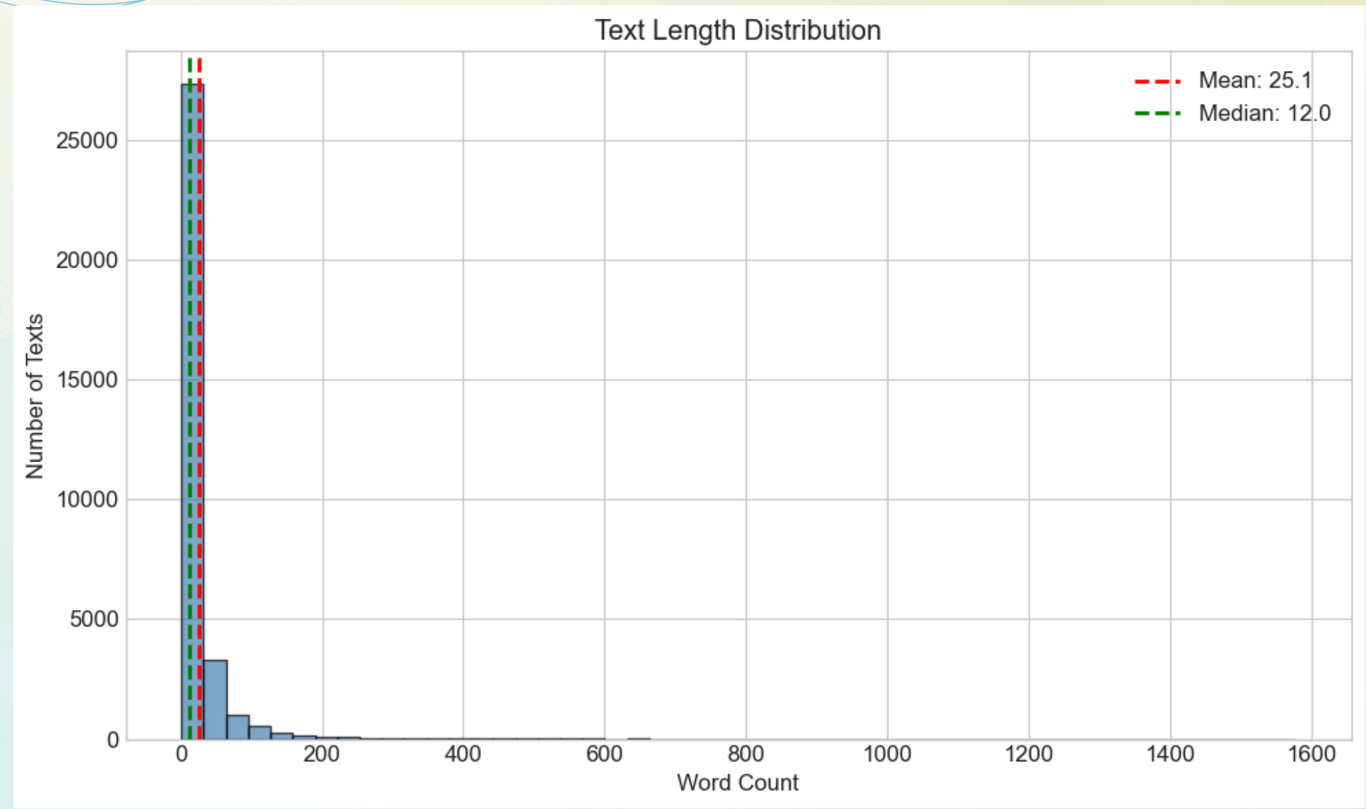



Có thể thấy có sự mất cân bằng nặng ở tỉ lệ các nhóm label ở cả phần sentiment và topic, phần sentiment chủ yếu là label Neutral, phần topic label chủ yếu là Other và Academic

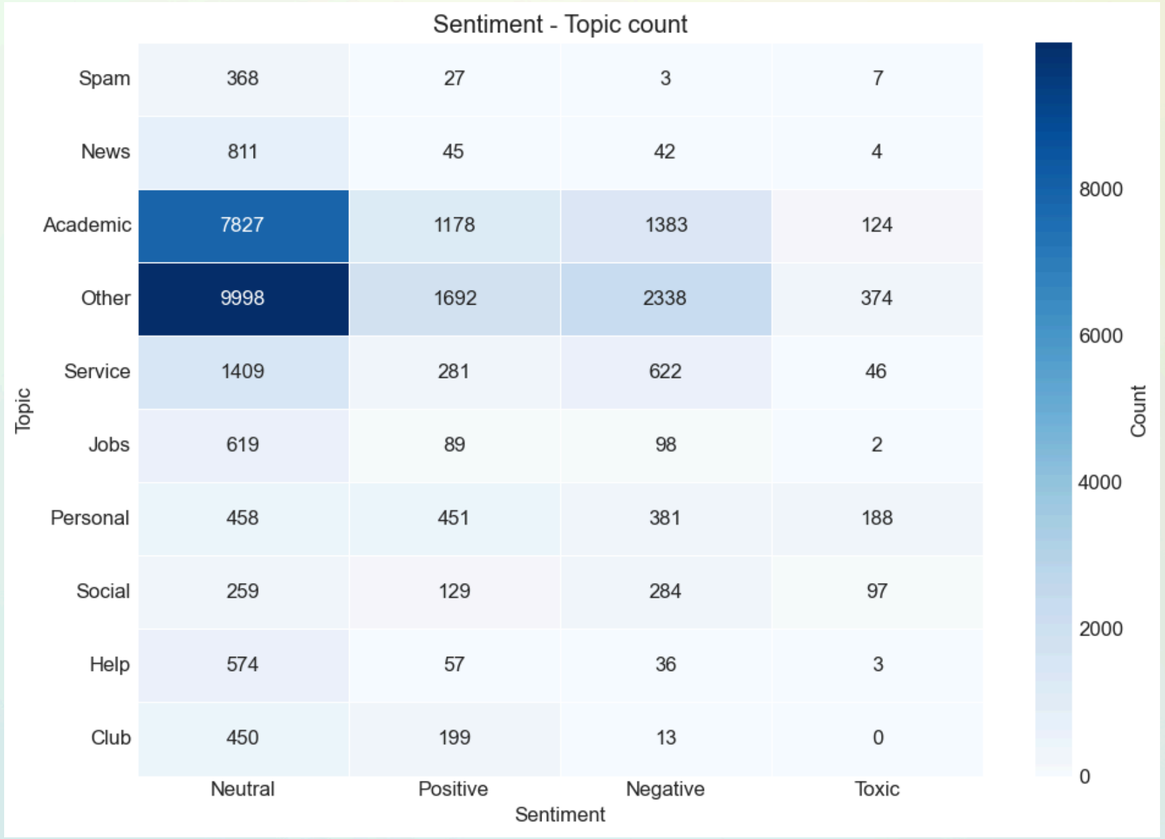
# 3 EDA

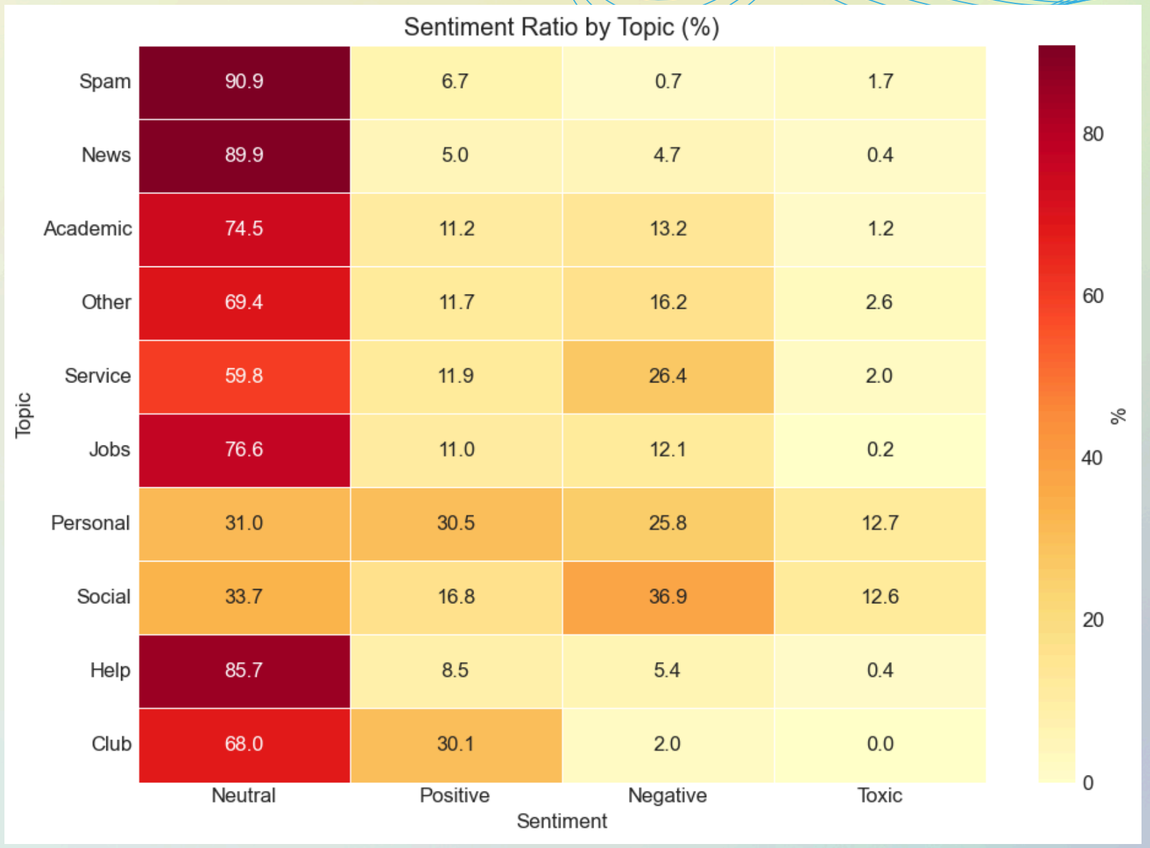
Trong dataset, các câu có độ dài từ **1 - 1578 từ**, số lượng từ vựng tất cả là **12759 từ**




**Từ biểu đồ, có thể thấy các câu có chủ yếu từ 1 - 25 từ mỗi câu**

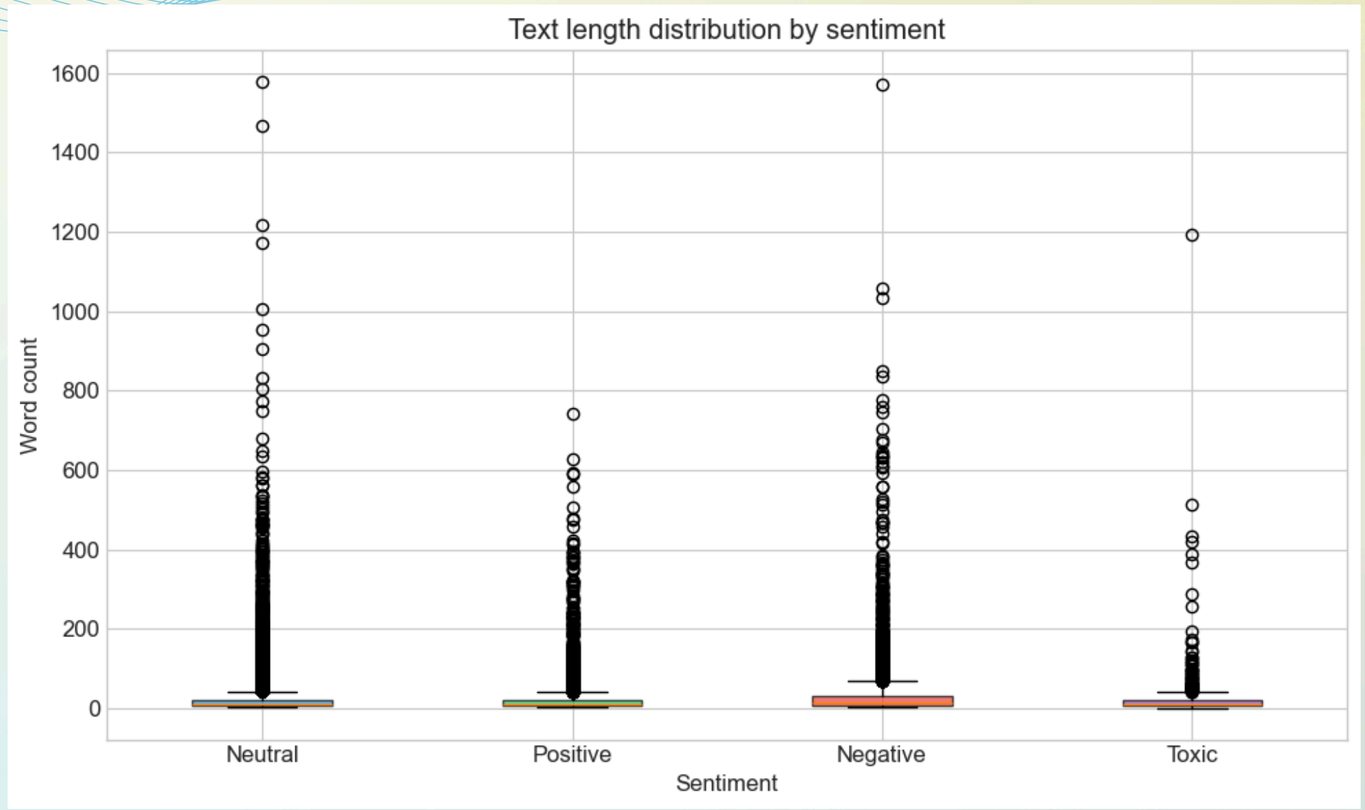
# 3 EDA



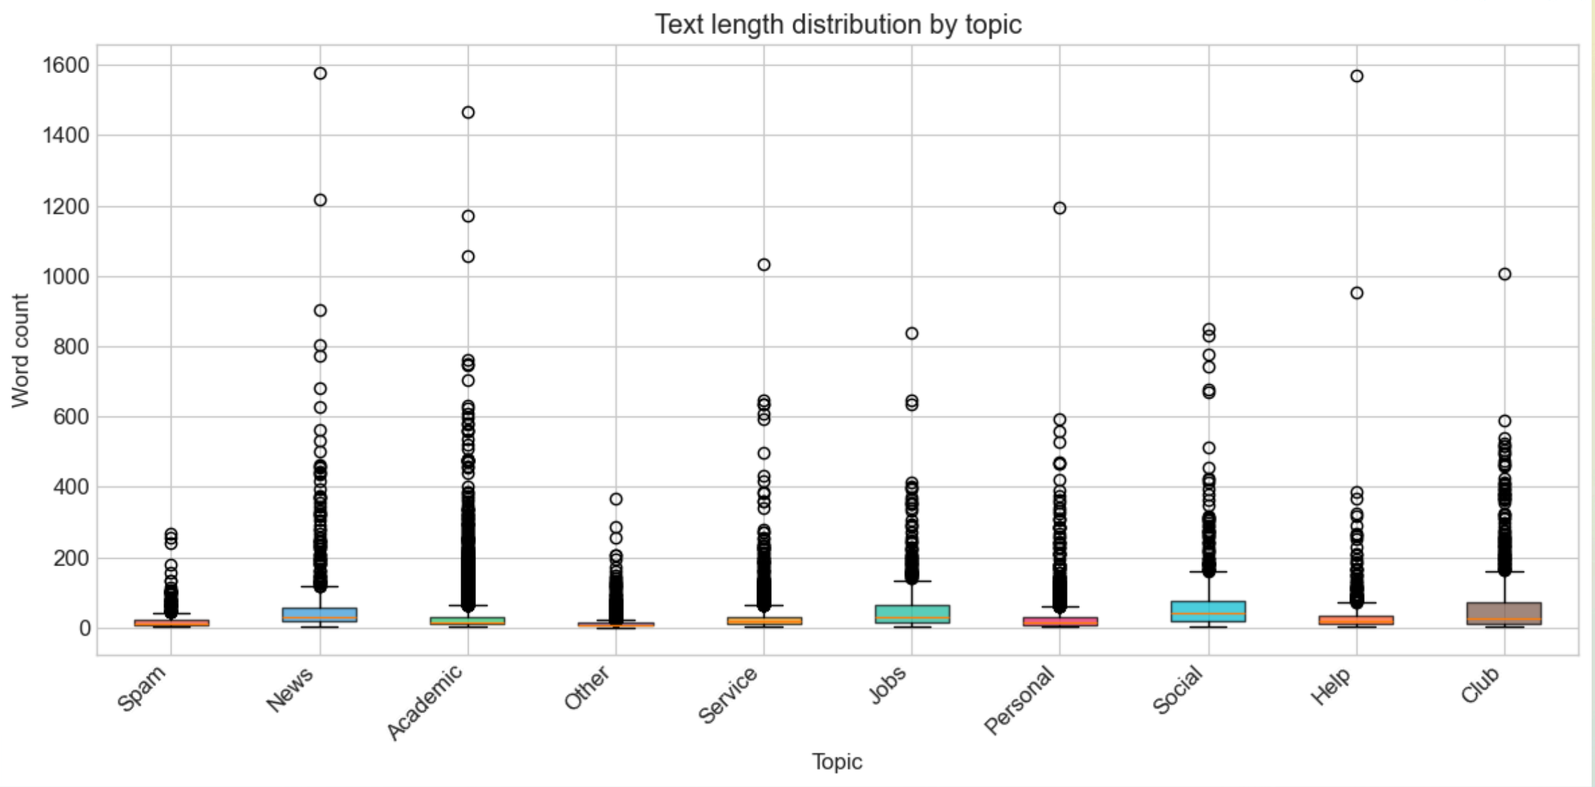




Ở mỗi topic, câu có sentiment Neutral chiếm rất nhiều, từ **31 - 90.9 %**

# 3 EDA


Text length distribution by sentiment
Word count
1600
1400
1200
1000
800
600
400
200
0
Neutral
Positive
Negative
Toxic
Sentiment

# 3 EDA


Text length distribution by topic
Word count
1600
1400
1200
1000
800
600
400
200
0
Spam
News
Academic
Other
Service
Jobs
Personal
Social
Help
Club
Topic

# 3 EDA

- Dữ liệu đã được chuyển đổi về dạng lowercase, không có các kí tự gây nhiễu như URL, emoji, hashtag
- Tỉ lệ các từ viết tắt chiếm số lượng rất nhỏ, ví dụ như: ko - > không (7 lần), cux - > cũng (5 lần), đc - > được (1 từ)
- Có thể thấy dữ liệu đã sạch, nên không cần bước tiền xử lí chung cho tập dữ liệu
- Ngoài ra các mô hình sử dụng đã được pre-trained với lượng dữ liệu lớn, đa dạng, nên việc dùng data augmentation cho các lớp thiểu số không cải thiện khả năng nhận diện chính xác

# 4 Mô hình baseline

**Mô hình baseline sử dụng Logistic Regression kết hợp với TF–IDF nhằm xây dựng một mốc so sánh đơn giản nhưng hiệu quả cho bài toán nhận diện cảm xúc và phân loại chủ đề.**

| Metric | Sentiment | Topic |
|---|---|---|
| Accuracy | 0.7473 | 0.7010 |
| Macro F1 | 0.6806 | 0.5553 |
| Weighted F1 | 0.7580 | 0.7192 |

Có thể thấy rằng các mô hình sẽ xử lí nhận dạng cảm xúc tốt hơn nhận dạng chủ đề, khai thác được các tín hiệu từ vựng bề mặt

# 5 Finetune các mô hình LLM Encoder - only

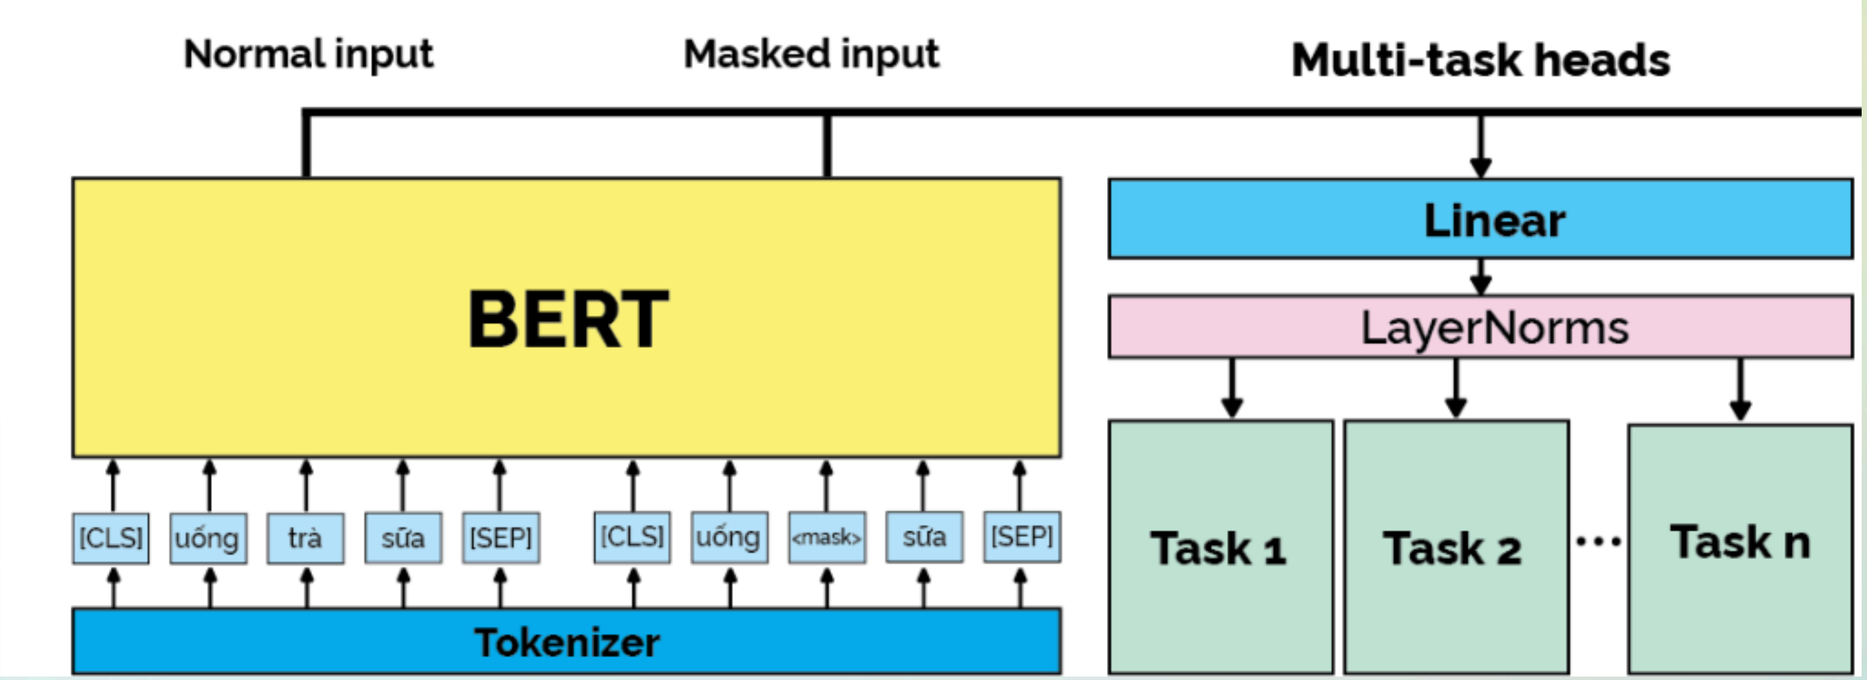
**a) Giới thiệu:**

- PhoBERT-base-v2 là mô hình ngôn ngữ pre-trained dành riêng cho tiếng Việt, sử dụng kiến trúc RoBERTa (Robustly Optimized BERT). Mô hình được huấn luyện trên khoảng 20GB dữ liệu tiếng Việt từ Wikipedia và các nguồn tin tức. Cấu trúc gồm 12 transformer layers, 768 hidden size, 12 attention heads với tổng cộng khoảng 135 triệu tham số. PhoBERT sử dụng word segmentation trước khi tokenize, phù hợp với đặc thù ngôn ngữ tiếng Việt

- XLM-RoBERTa-base là mô hình ngôn ngữ đa ngôn ngữ , được huấn luyện trên 2.5TB dữ liệu CommonCrawl từ 100 ngôn ngữ khác nhau, bao gồm tiếng Việt. Cấu trúc gồm 12 transformer layers, 768 hidden size, 12 attention heads với khoảng 270 triệu tham số. Ưu điểm là khả năng transfer learning tốt giữa các ngôn ngữ, tuy nhiên có thể không tối ưu bằng các mô hình được huấn luyện riêng cho một ngôn ngữ cụ thể

- ViSoBERT là mô hình ngôn ngữ pre-trained được thiết kế chuyên biệt cho miền dữ liệu mạng xã hội tiếng Việt. Mô hình được huấn luyện trên tập dữ liệu lớn từ Facebook, YouTube, TikTok, bao gồm cả teencode và biểu tượng cảm xúc. ViSoBERT sử dụng kiến trúc dựa trên XLM-RoBERTa với 12 transformer layers, 768 hidden size và 12 attention heads. Ưu điểm nổi bật là hiệu suất vượt trội khi xử lý văn bản nhiễu, khắc phục hạn chế của các mô hình chỉ học trên văn bản chuẩn mực

# 5 Finetune các mô hình LLM Encoder - only




Cấu trúc BERT sử dụng

# 5 Finetune các mô hình LLM Encoder - only

**b) Cách finetune**

Nhóm tiền xử lí dữ liệu với mô hình phoBERT base V2 như sau:

- Loại bỏ các khoảng trắng thừa ở đầu, cuối và giữa các từ
- Sử dụng thư viện VnCoreNLP để tách từ ghép trong tiếng Việt. Các từ ghép được nối với nhau bằng dấu gạch dưới "_". (Ví dụ: "sinh viên" → "sinh_viên", "đại học" → "đại_học"). Bước này rất quan trọng vì PhoBERT được huấn luyện trên dữ liệu đã qua tách từ
- Sử dụng Tokenizer của mô hình để chuyển đổi văn bản thành các token <IDs> mà mô hình có thể hiểu được. Quá trình này bao gồm: thêm các token đặc biệt <s> ở đầu và </s> ở cuối câu, cắt ngắn nếu văn bản quá dài (max 256 tokens), và thêm <pad> token nếu văn bản quá ngắn để đảm bảo độ dài đồng nhất. Áp dụng BPE để tokenize

Đối với tiền xử lí dữ liệu cho mô hình XLM-RoBERTa và VisoBERT, gần giống như PhoBERT, chỉ khác ở chỗ không cần tách từ, vì đây là mô hình đa ngôn ngữ, có thể tự động xử lý, sử dụng Unigram Language Model để tokenize

Fine-tune bằng cách load mô hình pretrained, thêm một shared linear layer và layer normalization, sau đó chia thành hai classification heads tương ứng với 2 nhiệm vụ (sentiment analysis và topic classification), sử dụng Focal loss vì có khả năng xử lí tốt với dữ liệu mất cân bằng, gradient clipping để tránh đạo hàm quá lớn, áp dụng learning rate khác nhau cho backbone và classification head, Linear warm-up with linear/cosine decay

# 5 Finetune các mô hình LLM Encoder - only

Để tăng cường hiệu quả khi finetune mô hình, nhóm đã áp dụng các kĩ thuật sau, so sánh khi dùng từng kĩ thuật riêng lẻ và khi kết hợp:

- Masked Language Modeling (MLM)
- Smoothness-inducing Adversarial Regularization Technique (SMART)

MLM (Masked Language Modeling): mô hình được mở rộng thêm một MLM head (Masked Language Model) tạo thành kiến trúc 3-head. MLM head có nhiệm vụ dự đoán các token bị che (mask): 30% tokens được chọn ngẫu nhiên, trong đó 80% được thay bằng <MASK>, 10% bị gán nhãn sai, và 10% giữ nguyên. Do loss của MLM thường lớn hơn nhiều so với hai task chính, giá trị này được chia cho số lượng masked tokens trung bình mỗi câu để cân bằng. Loss tổng được tính: L(total) = L(sentiment) + L(topic) + L(MLM) / n, trong đó n là số lượng mask tokens che trung bình mỗi câu

# 5 Finetune các mô hình LLM Encoder - only

SMART (Smoothness-inducing Adversarial Regularization Technique) là kỹ thuật regularization được nhằm cải thiện khả năng tổng quát hóa của mô hình ngôn ngữ khi fine-tuning. Ý tưởng là buộc mô hình phải cho ra kết quả ổn định khi đầu vào bị thay đổi nhỏ, giúp mô hình ổn định hơn với nhiễu và tránh overfitting. SMART bao gồm hai thành phần chính: Smoothness-inducing Adversarial Regularization và Bregman Proximal Point Optimization

Smoothness-inducing Adversarial Regularization: Thêm nhiễu nhỏ vào input, buộc mô hình vẫn phải cho ra kết quả giống như không có nhiễu như sau:

- Tìm nhiễu r làm output thay đổi nhiều nhất:

$$\tilde{r} = \arg\max_{r} \; D_{\mathrm{KL}}(P(y \mid x) \,\|\, P(y \mid x + r))$$

- Phạt nếu output có nhiễu khác output gốc:

$$\mathcal{L}_s = D_{\mathrm{KL}}(P(y \mid x) \,\|\, P(y \mid x + \tilde{r}))$$

# 5 Finetune các mô hình LLM Encoder - only

Bregman Proximal Point Optimization:  Ngăn mô hình thay đổi quá nhanh, giữ lại kiến thức từ pre-training như sau
Phạt nếu output hiện tại khác output bước trước:

$$\mathcal{L}_b = D_{\mathrm{KL}}(P_{\theta^{(t-1)}}(y \mid x) \,\|\, P_{\theta^{(t)}}(y \mid x))$$

Loss tổng khi finetune mô hình như sau:

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \lambda \mathcal{L}_{\text{SMART}}$$

# 5 Finetune các mô hình LLM Encoder - only

Kết quả như sau

| Mô hình | Phương pháp | Sentiment accuracy | Sentiment F1 | Topic accuracy | Topic F1 |
|---|---|---|---|---|---|
| **PhoBERT** | **Finetune thường** | **82.16%** | 0.82 | 76.61% | 0.77 |
| **PhoBERT** | **MLM** | 80.84% | 0.81 | 76.82% | 0.77 |
| **PhoBERT** | **SMART** | 81.26% | 0.82 | **77.35%** | **0.78** |
| **PhoBERT** | **MLM + SMART** | 80.31% | 0.81 | 75.00% | 0.76 |
| **VisoBERT** | **Finetune thường** | 81.70% | 0.8171 | 76.68% | 0.7687 |
| **VisoBERT** | **MLM** | 80.96% | 0.8092 | 77.53% | 0.7758 |
| **VisoBERT** | **SMART** | 81.99% | 0.8185 | 77.79% | 0.7783 |
| **VisoBERT** | **MLM + SMART** | **82.19%** | **0.8244** | **79.01%** | **0.7897** |

# 5 Finetune các mô hình LLM Encoder - only

| Mô hình | Phương pháp | Sentiment accuracy | Sentiment F1 | Topic accuracy | Topic F1 |
|---|---|---|---|---|---|
| **XLM-RoBERTa** | **Finetune thường** | 79.80% | 0.80 | 77.09% | 0.77 |
| **XLM-RoBERTa** | **MLM** | 81.63% | 0.82 | 77.85% | 0.78 |
| **XLM-RoBERTa** | **SMART** | 80.89% | 0.81 | **77.97%** | 0.78 |
| **XLM-RoBERTa** | **MLM + SMART** | **81.69%** | 0.82 | 78.24% | **0.79** |

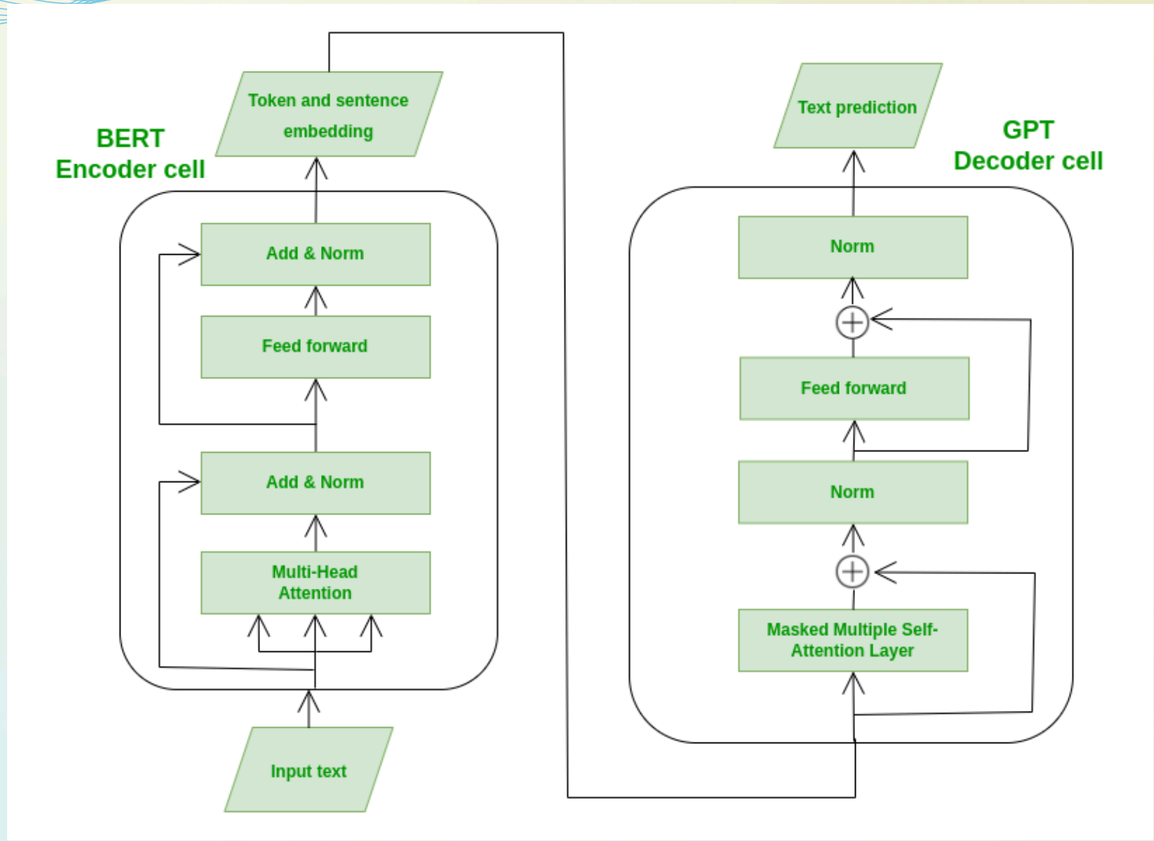
# 6 Finetune LLM với các mô hình Seq2Seq

**a) Giới thiệu:**

- BARTpho là mô hình ngôn ngữ encoder–decoder dành riêng cho tiếng Việt, được phát triển dựa trên kiến trúc BART (Bidirectional and Auto-Regressive Transformer). Mô hình được huấn luyện trên tập dữ liệu lớn gồm Wikipedia và các nguồn tin tức tiếng Việt, với mục tiêu chính là text generation và text-to-text tasks. BARTpho gồm hai phiên bản chính là BARTpho-base và BARTpho-large, trong đó phiên bản base có 6 encoder layers và 6 decoder layers, hidden size 768, tổng cộng khoảng 139 triệu tham số. Nhờ kết hợp khả năng mã hóa ngữ cảnh hai chiều và sinh chuỗi tự hồi quy, hiệu quả cho các bài toán như tóm tắt văn bản, sinh câu và chuyển đổi văn bản.

- ViT5 (Vietnamese T5) là mô hình ngôn ngữ text-to-text dành cho tiếng Việt, được xây dựng dựa trên kiến trúc T5 (Text-To-Text Transfer Transformer). ViT5 được huấn luyện trên tập dữ liệu tiếng Việt quy mô lớn, trong đó mọi tác vụ NLP đều được ánh xạ về dạng text input → text output. Kiến trúc ViT5 bao gồm encoder–decoder transformer với cơ chế self-attention và cross-attention, cho phép mô hình học biểu diễn ngữ nghĩa tổng quát và linh hoạt. Nhờ thiết kế thống nhất cho nhiều tác vụ, ViT5 hiệu quả cao trong các bài toán như phân loại văn bản, hỏi–đáp, tóm tắt và sinh văn bản tiếng Việt.

# 6 Finetune LLM với các mô hình Seq2Seq



# 6 Finetune LLM với các mô hình Seq2Seq

**b) Cách finetune**

## Full Fine-tuning

- **Transfer learning:** sử dụng lại tri thức của các mô hình lớn (ViT5/BARTpho) đã được huấn luyện sẵn trên dữ liệu khổng lồ, chuyển giao toàn bộ kiến thức đó sang bài toán của mình.
- **Tiền xử lý dữ liệu:** Giống với tiền xử lý dữ liệu của PhoBert
- **Weighted Loss:** can thiệp vào hàm Loss, thiết lập hệ số phạt. Model đoán sai nhãn hiếm thì bị phạt rất nặng, còn đoán sai nhãn thường thì bị phạt nhẹ.

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N} w_{y_i} \log(\hat{y}_i)$$

- **Multi-task Learning:** dùng chung một "bộ não" Encoder. Khi mô hình học được đặc trưng của "Cảm xúc", nó dùng luôn thông tin đó để bổ trợ cho việc đoán "Chủ đề".

# 6 Finetune LLM với các mô hình Seq2Seq

**b) Cách finetune**

**LoRA (Low-Rank Adaptation)** là kỹ thuật tinh chỉnh hiệu quả tham số, cho phép huấn luyện các mô hình ngôn ngữ lớn trên phần cứng giới hạn

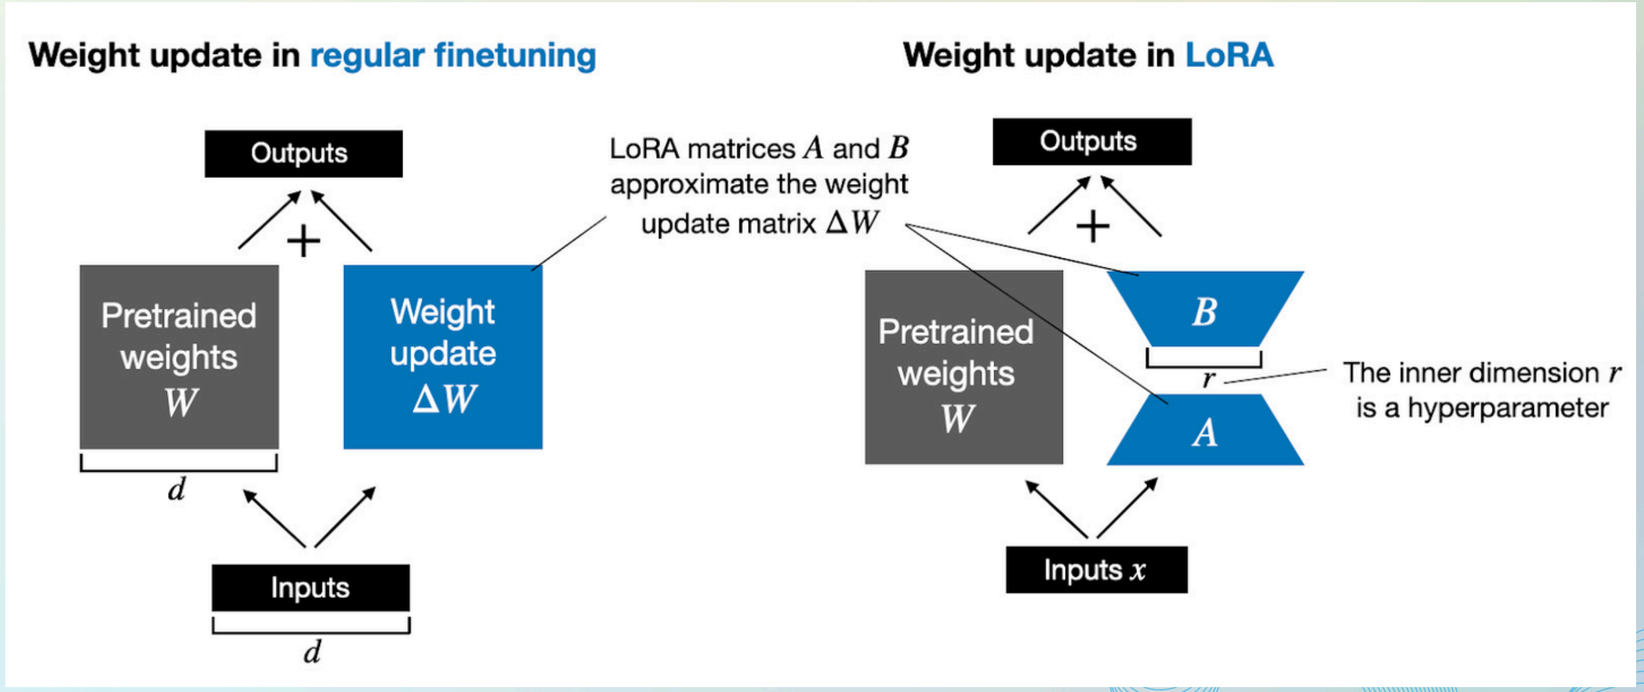
Cơ chế hoạt động: Thay vì cập nhật toàn bộ tham số, LoRA chỉ thêm một phép nhân ma trận nhỏ B x A để chỉ cần cập nhật một lượng nhỏ tham số mô hình mà vẫn đảm bảo hiệu quả khi finetune

Công thức:

$W' = W + \Delta W = W + B \times A$

Trong đó:

- W (d x k): trọng số gốc (frozen, không train)
- B (d x r): ma trận nhỏ
- A (r x k): ma trận nhỏ
- r: thường rất nhỏ so với d, k



# Kết quả

## Sentiment

| Mô hình | Phương pháp | Sentiment accuracy | Sentiment Recall | Sentiment F1 |
|---|---|---|---|---|
| **Bartpho-word** | **Full Fine-tune** | 79.16% | 0.79 | 0.80 |
| **Bartpho-word** | **LoRA** | 75.23% | 0.77 | 0.76 |
| **ViT5-base** | **Full Fine-tune** | **80.96%** | **0.81** | **0.81** |
| **ViT5-base** | **LoRA** | 73.11% | 0.73 | 0.73 |

# Kết quả

## Topic

| Mô hình | Phương pháp | Topic accuracy | Topic Recall | Topic F1 |
|---|---|---|---|---|
| **Bartpho-word** | **Full Fine-tune** | 75.44% | 0.75 | 0.76 |
| **Bartpho-word** | **LoRA** | 70% | 0.69 | 0.71 |
| **ViT5-base** | **Full Fine-tune** | **75.99%** | **0.76** | **0.76** |
| **ViT5-base** | **LoRA** | 73.19% | 0.73 | 0.74 |

# NEU Student Confessions Analyzer

Hệ thống phân loại Cảm xúc & Chủ đề đa nhiệm (4 Models)

**Nội dung Confession**

Vãi cả đái mấy bọn xài tool đăng kí học phần làm cho tao mất slot, làm tao rất đéo hài lòng

**Chọn Mô Hình AI**

ViT5-base (Best Acc)

Phân Tích Ngay

Chi tiết kỹ thuật (Debug)

## Kết quả Phân tích

**Cảm xúc (Sentiment)**

Label

**Toxic (Độc hại)**

| | |
|---|---|
| Toxic (Độc hại) | 100% |
| Negative (Tiêu cực) | 0% |
| Positive (Tích cực) | 0% |
| Neutral (Trung tính) | 0% |

**Chủ đề (Topic)**

Label

**Academic (Học tập)**

| | |
|---|---|
| Academic (Học tập) | 35% |
| Spam | 14% |
| Personal (Tâm sự) | 10% |
| Social (Xã hội) | 9% |
| Help (Hỏi đáp) | 8% |

# Thank you for paying your attention